



**UNIVERSIDAD POLITÉCNICA DE PACHUCA**  
**PROGRAMA EDUCATIVO DE INGENIERÍA EN SOFTWARE**  
**ASIGNATURA: INTELIGENCIA ARTIFICIAL**

---

**MANUAL TÉCNICO Y TEÓRICO PEDAGÓGICO  
COMPLETO:**  
**GUÍA DE FUNDAMENTACIÓN DESDE CERO**  
*Simulación Poisson, Regresión OLS, Supuestos de Gauss-Markov, Algoritmo UCB1 y Código  
Python*

---

**Información Institucional del Proyecto**

|                            |                                                         |
|----------------------------|---------------------------------------------------------|
| <b>Autores:</b>            | Emmanuel Islas Lozada<br>Ximena Nathaly Angeles Sanchez |
| <b>Grado y Grupo:</b>      | 8º Cuatrimestre – Ingeniería en Software                |
| <b>Asignatura:</b>         | Inteligencia Artificial                                 |
| <b>Proyecto:</b>           | Sistema Inteligente de Despacho mediante RL y OLS       |
| <b>Fecha de Entrega:</b>   | Agosto 2026                                             |
| <b>Versión de Release:</b> | v1.0.0 Final Master                                     |



# Índice

# 1. Introducción Pedagógica y Problema Operativo

## 1.1. El Dilema Diario del Transporte en la UPP

La Universidad Politécnica de Pachuca (UPP) enfrenta diariamente un reto de movilidad crítico para su comunidad estudiantil. Cientos de alumnos deben trasladarse entre el campus universitario y puntos estratégicos de la zona metropolitana, como la ruta **Puente Tuzos** y la **Central de Autobuses**.

El servicio de transporte colectivo es prestado por unidades tipo *combi*”, las cuales tienen una capacidad máxima física y legal estricta de  $C = 18$  pasajeros por unidad.

## 1.2. El Conflicto de Intereses: Operador vs. Estudiante

Existe una tensión estructural entre las dos partes involucradas en el sistema:

1. **El Chofer / Concesionario (Criterio Económico):** Desea maximizar la ganancia por cada viaje. Para lograrlo, prefiere esperar en la bahía hasta que la unidad esté completamente llena con los 18 pasajeros (100 % de ocupación), evitando llevar asientos vacíos que representen costo consumido sin cobro.
2. **El Estudiante (Criterio de Calidad de Servicio):** Desea llegar a tiempo a sus clases o retornar rápidamente a su hogar. Esperar demasiado en la bahía de salida genera frustración, retrasos en exámenes y riesgo de quedar varado al cierre de la jornada.

## 1.3. Por qué la Regla Rígida Actual Falla

La política operativa tradicional (denominada en este proyecto como brazo  $a_0$ ) es rígida: la *combi* no arranca hasta juntar a los 18 alumnos.

- **En Hora Pico (07:00-09:00 y 13:00-15:00):** La regla funciona bien porque llegan decenas de alumnos por minuto y la unidad se llena en 2 a 4 minutos.
- **En Hora Valle (10:00-12:00 y 16:00-18:00):** La llegada de alumnos disminuye drásticamente. Obligar a la *combi* a esperar 18 alumnos provoca que la primera persona que subió pase entre 60 y 85 minutos adentro de la unidad estacionada.

## 1.4. Arquitectura de la Solución Inteligente

Para resolver este problema con rigor científico, la solución se divide en dos bloques conceptuales:



1. **Módulo Predictivo (Regresión Lineal MCO/OLS):** Modela la física del tiempo de espera en función del número de personas en la cola, permitiendo estimar el tiempo restante para completar la combi.
2. **Módulo Prescriptivo (Aprendizaje por Refuerzo UCB1):** Un agente inteligente toma la decisión en tiempo real sobre cuál política aplicar (por ejemplo: *"Si pasaron 15 minutos y hay 14 pasajeros, salir inmediatamente"*), logrando el equilibrio perfecto entre rentabilidad y rapidez.

## 2. Teoría de Probabilidad y Simulación de Arribos de Poisson

### 2.1. ¿Qué es un Proceso Estocástico?

Un proceso estocástico o aleatorio es una secuencia de variables que evolucionan a lo largo del tiempo siguiendo leyes de probabilidad. En lugar de saber exactamente a qué segundo llegará cada estudiante, modelamos la frecuencia con la que ocurren los arribos.

### 2.2. La Distribución de Poisson Explicada Desde Cero

La **Distribución de Poisson** es la función matemática por excelencia para contar el número de eventos independientes que ocurren dentro de un intervalo fijo de tiempo o espacio.

La Función de Masa de Probabilidad (PMF) de Poisson se define como:

$$P(N(t) = k) = \frac{(\lambda t)^k \cdot e^{-\lambda t}}{k!} \quad (1)$$

Desglose detallado de cada componente de la fórmula:

- $N(t)$ : Variable aleatoria discreta que representa el número total de alumnos que llegan en el intervalo de tiempo  $t$ .
- $k$ : El número exacto de alumnos sobre el cual queremos calcular la probabilidad ( $k = 0, 1, 2, 3, \dots$ ).
- $\lambda$  (Letra griega *Lambda*): Representa la **tasa promedio de arribos por unidad de tiempo** (por ejemplo,  $\lambda = 3,5$  alumnos por minuto).
- $e$ : Constante matemática fundamental conocida como número de Euler ( $e \approx 2,718281828$ ).
- $k!$ : El **factorial** del número  $k$ , definido como  $k! = k \times (k - 1) \times (k - 2) \times \dots \times 1$ . Por definición matemática,  $0! = 1$ .

### 2.3. Propiedades Clave de la Distribución de Poisson

1. **Media y Varianza Iguales:** La media esperada de eventos es  $\mathbb{E}[N(t)] = \lambda t$ , y su varianza es exactamente igual:  $\text{Var}(N(t)) = \lambda t$ .
2. **Independencia de Intervalos:** Lo que ocurre en un intervalo de 15 minutos no afecta el número de llegadas en el siguiente intervalo.

## 2.4. Modelado de la Tasa Variable $\lambda(t)$ por Franja Horaria

En el transporte universitario, asumir una tasa constante sería irreal. Por ello, en el script `src/data_generator.py` implementamos una tasa de llegada adaptativa según la hora del día:

Tabla 1: Tasas de Arribo Poisson  $\lambda(t)$  en la Simulación

| Franja Horaria                      | Tasa $\lambda$ (alumnos/min) | Comportamiento Físico de la Cola                  |
|-------------------------------------|------------------------------|---------------------------------------------------|
| Hora Pico Matutina (07:00–09:00)    | $\lambda = 3,5$              | Cola alta. Los 18 asientos se ocupan rápidamente. |
| Hora Valle Intermedia (10:00–12:00) | $\lambda = 1,2$              | Cola baja. Llegadas esporádicas de alumnos.       |
| Hora Pico Vespertina (13:00–15:00)  | $\lambda = 3,5$              | Salida de clases. Congestión alta en la bahía.    |
| Hora Valle Tardía (16:00–18:00)     | $\lambda = 1,2$              | Flujo reducido de estudiantes al final del día.   |

### 3. Fundamentos de Regresión Lineal Simple MCO (OLS)

#### 3.1. ¿Qué es una Regresión Lineal Simple?

La Regresión Lineal Simple es un método estadístico supervisado que busca explicar la relación entre una variable independiente o explicativa ( $X$ ) y una variable dependiente o de respuesta ( $Y$ ) a través de una línea recta:

$$Y_i = a + b \cdot X_i + e_i \quad (2)$$

Donde:

- $X_i$ : Número de alumnos esperando en la combi al llegar (`alumnos_esperando`).
- $Y_i$ : Minutos acumulados transcurridos hasta el despacho (`minutos_para_llenar`).
- $a$ : **Intercepto** (el valor predicho de  $Y$  cuando  $X = 0$ ).
- $b$ : **Pendiente** (cuánto cambia  $Y$  por cada alumno adicional en la cola).
- $e_i$ : **Residuo o error** de la observación  $i$ , dado por  $e_i = Y_i - \hat{Y}_i$ .

#### 3.2. El Criterio de Mínimos Cuadrados Ordinarios (MCO / OLS)

El método OLS (*Ordinary Least Squares*) busca la recta  $(a, b)$  que minimice la Suma de Errores al Cuadrado (SSE):

$$\min_{a,b} \text{SSE} = \min_{a,b} \sum_{i=1}^n e_i^2 = \min_{a,b} \sum_{i=1}^n (Y_i - (a + bX_i))^2 \quad (3)$$

Derivando parcialmente con respecto a  $a$  y  $b$  e igualando a cero, obtenemos las fórmulas analíticas exactas:

#### Fórmulas Analíticas de los Estimadores OLS

$$b = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2} = \frac{\text{Cov}(X, Y)}{\text{Var}(X)}, \quad a = \bar{Y} - b\bar{X} \quad (4)$$

#### 3.3. Resultados Obtenidos en el Proyecto (Modelo 2)

Al procesar las  $n = 1,466$  observaciones del dataset filtrado, obtenemos:

$$\hat{Y} = 14,106834 - 2,539453 \cdot X \quad (5)$$

### 3.3.1. Explicación Detallada de los Resultados

- **Intercepto** ( $a = 14,11$  min): Si una combi llega a la parada vacía y no hay nadie en la cola ( $X = 0$ ), el tiempo promedio predicho para salir es de **14.11 minutos**.
- **Pendiente** ( $b = -2,54$  min/alumno): Signo negativo totalmente lógico: por cada alumno que ya esté en la cola al llegar la unidad, el tiempo de espera restante disminuye en promedio **2.54 minutos**.
- **Coefficiente de Determinación** ( $R^2 = 0,1210$ ): El número de personas en la cola explica el **12.1 %** de la variabilidad total del tiempo. El 87,9 % restante de la varianza se debe a factores estocásticos no medidos por una sola recta (diferencia entre horas pico y valle).
- **Valor  $p$  de la pendiente** ( $p = 5,83 \times 10^{-43}$ ): Al ser menor que 0,05, se rechaza la hipótesis nula  $H_0 : b = 0$  con un **nivel de confianza**  $> 99,99 \%$ . La relación es altamente significativa.

#### Clarificación del $R^2 = 0,74$ Mencionado en la Plantilla de la Bitácora

En la página 5 del documento de instrucciones de la asignatura (Proyecto final IA.pdf), se incluye una tabla con un **ejemplo hipotético de bitácora** donde aparece escrito  $R^2 = 0.74$ ". Ese valor era simplemente una cifra de muestra inventada para ilustrar cómo llenar la plantilla. En nuestro proyecto con datos simulados realistas y ruido en hora valle, el resultado empírico científicamente correcto es  $R^2 = 12,1 \%$  con  $p < 10^{-40}$ .



## 4. Diagnóstico Pedagógico de los 5 Supuestos de Gauss-Markov

El Teorema de Gauss-Markov establece que si se cumplen 5 supuestos básicos sobre los residuos, los estimadores OLS son **BLUE** (*Best Linear Unbiased Estimator* / El Mejor Estimador Lineal Insesgado). A continuación se explica cada supuesto con manzanas”:

### 4.1. 1. Supuesto de Linealidad

**¿Qué significa?** Que la relación entre la variable  $X$  y la variable  $Y$  puede representarse adecuadamente mediante una línea recta.

- **Diagnóstico en el Proyecto:** Se evaluó agregando un término cuadrático  $X^2$ . La prueba  $F$  dio  $F = 25,86$  ( $p < 0,001$ ), lo que indica que aunque la recta captura la tendencia decreciente general, existe una ligera curvatura natural.

### 4.2. 2. Supuesto de Independencia de los Errores (No Autocorrelación)

**¿Qué significa?** Que el error de predicción en el despacho de una combi no depende ni influye en el error del despacho siguiente.

- **Medición Estadística:** Se utilizó la prueba de **Durbin-Watson** ( $DW$ ):

$$DW = \frac{\sum_{i=2}^n (e_i - e_{i-1})^2}{\sum_{i=1}^n e_i^2} \quad (6)$$

- $DW = 2,0$  significa independencia perfecta.
- En nuestro modelo  $DW \approx 0,17$ , indicando una autocorrelación positiva leve.
- **Explicación del Fenómeno:** Ocurre porque los alumnos llegan a la parada en ráfagas.<sup>o</sup> grupos de amigos (.<sup>en</sup> bolas”) al salir de una misma clase, condicionando el tiempo entre arribos consecutivos.

### 4.3. 3. Supuesto de Homocedasticidad (Varianza Constante)

**¿Qué significa?** Que la dispersión (varianza) de los errores debe ser la misma sin importar si  $X$  es pequeño o grande.

- **Diagnóstico en el Proyecto:** Se aplicó la prueba de **Breusch-Pagan** ( $p < 0,05$ ), rechazando la homocedasticidad (existe **Heterocedasticidad**).
- **Explicación Intuitiva con Manzanas:**
  - En las mañanas (**Hora Pico**), la combi se llena tan rápido que el error del modelo es de apenas  $\pm 1$  a 2 minutos.
  - En las tardes (**Hora Valle**), las llegadas son muy erráticas y el error de predicción puede variar hasta en  $\pm 10$  minutos.

#### 4.4. 4. Supuesto de Esperanza Matemática Nula ( $\mathbb{E}[e] = 0$ )

**¿Qué significa?** Que el promedio de todos los errores de predicción a lo largo del tiempo debe ser exactamente cero (los errores positivos se cancelan con los negativos).

- **Resultado: Cumple 100 %.** Por propiedades matemáticas de MCO, la suma de los residuos  $\sum e_i = 0$ , garantizando que  $\bar{e} = 0$ .

#### 4.5. 5. Supuesto de Normalidad de los Residuos

**¿Qué significa?** Que si graficas un histograma de los errores de predicción, estos deben formar una Campana de Gauss centrada en cero.

- **Resultado:** Riesgo moderado. La mayoría de los errores se concentran en el centro, pero presentan colas más anchas debido a las esperas prolongadas de las horas valle.

## 5. Aprendizaje por Refuerzo Prescriptivo y Algoritmo UCB1

### 5.1. ¿Por qué pasamos de OLS a Aprendizaje por Refuerzo?

La Regresión Lineal OLS nos dice *qué va a pasar en promedio* (es un modelo **predictivo**), pero **no toma decisiones**. No le puede decir al chofer: *"Despacha la combi ahorita con 14 personas porque es hora valle"*.

Para **tomar decisiones autónomas optimizadas**, utilizamos el **Aprendizaje por Refuerzo** (Reinforcement Learning - RL).

### 5.2. El Problema del Bandit Multibrazo (Multi-Armed Bandit)

Imagina que estás en un casino frente a una máquina tragamonedas con 5 palancas (brazos). Cada palanca entrega una ganancia promedio diferente, pero no sabes cuál es la mejor.

- Si solo apuestas por la palanca que mejor te ha pagado al principio, podrías estar perdiendo una palanca mucho mejor que no has probado suficiente (**Dilema de Exploración vs. Explotación**).

### 5.3. Definición de los 5 Brazos (Acciones del Agente)

En nuestro sistema de despacho UPP, los 5 brazos representan diferentes políticas operativas:

Tabla 2: Catálogo de Brazos (Acciones) del Agente

| Brazo | Nombre               | Regla de Despacho                                                |
|-------|----------------------|------------------------------------------------------------------|
| $a_0$ | Llenado_Estricto_18p | Salir solo con 18 pasajeros (Política Tradicional).              |
| $a_1$ | Flex_14p_15m         | Salir con $\geq 14$ pasajeros O si pasaron 15 minutos de espera. |
| $a_2$ | Flex_12p_25m         | Salir con $\geq 12$ pasajeros O si pasaron 25 minutos de espera. |
| $a_3$ | Flex_10p_35m         | Salir con $\geq 10$ pasajeros O si pasaron 35 minutos de espera. |
| $a_4$ | Max_Espera_45m       | Salir si pasaron 45 minutos o al juntar mínimo 8 pasajeros.      |

## 5.4. La Función de Recompensa Normalizada $R \in [0, 1]$

Cada vez que el agente ejecuta una acción, el entorno le otorga una recompensa escalar  $R \in [0, 1]$ , donde 1,0 es un despacho perfecto y 0,0 es un desempeño pésimo:

$$R = 1,0 - \left( 0,4 \cdot \frac{\text{espera\_min}}{60} + 0,4 \cdot \frac{\text{alumnos\_varados}}{30} + 0,2 \cdot \frac{\text{asientos\_vacios}}{18} \right) \quad (7)$$

## 5.5. Ecuación y Funcionamiento del Algoritmo UCB1

En cada despacho  $t$ , el algoritmo **UCB1** (*Upper Confidence Bound 1*) selecciona el brazo  $a(t)$  que maximiza la fórmula:

$$a(t) = \arg \max_{j \in \{0, \dots, 4\}} \left[ \bar{Q}_j(t) + c \cdot \sqrt{\frac{2 \cdot \ln t}{N_j(t)}} \right] \quad (8)$$

Desglose detallado término por término:

- $\bar{Q}_j(t)$ : **Término de Explotación.** La recompensa promedio obtenida por el brazo  $j$  hasta el momento.
- $c$ : **Constante de Exploración.** Controla la disposición a arriesgarse (fijada en  $c = 1,414 \approx \sqrt{2}$ ).
- $t$ : Número total de despachos realizados por todas las políticas juntas.
- $\ln t$ : Logaritmo natural de  $t$ . Crece lentamente a medida que pasa el tiempo, haciendo que el deseo de explorar no desaparezca por completo.
- $N_j(t)$ : Número de veces que se ha seleccionado específicamente el brazo  $j$ . Si un brazo se ha probado pocas veces,  $N_j(t)$  es muy pequeño, provocando que la división estalle hacia arriba y la raíz cuadrada dé un valor alto (**Bonus de Incertidumbre**), forzando al agente a probar ese brazo.

## 6. Análisis Paso a Paso del Código Fuente Python

El proyecto está estructurado modularmente en el directorio `src/` y 3 scripts principales de ejecución. A continuación se explica la lógica de los componentes clave:

### 6.1. 1. Módulo de Configuración (`src/config.py`)

Define la estructura de directorios del proyecto mediante `pathlib.Path`, garantizando compatibilidad multiplataforma (Linux/Windows). Establece los parámetros globales como la capacidad de las combis ( $C = 18$ ), los pesos de recompensa ( $w_1 = 0,4, w_2 = 0,4, w_3 = 0,2$ ) y las semillas de reproducibilidad.

### 6.2. 2. Generación del Dataset (`src/data_generator.py`)

Implementa la función `generate_demand_dataset()`. Utiliza `numpy.random.default_rng().poisson(lam)` para simular los arribos en intervalos de 15 minutos durante 21 días. Aplica la tasa de llegada adaptativa  $\lambda(t)$  según el rango horario y genera las 13 columnas del dataset oficial.

### 6.3. 3. Módulo de Regresión MCO (`src/regression_model.py`)

Contiene la función `fit_ols(df)`, la cual calcula analíticamente la pendiente  $b$  y el intercepto  $a$  usando `numpy` y `scipy.stats.linregress`. Además, la función `calculate_diagnostics()` ejecuta la prueba de Durbin-Watson para autocorrelación y la prueba de Breusch-Pagan para heterocedasticidad.

### 6.4. 4. Agente UCB1 (`src/ucb_bandit.py`)

Implementa la clase `UCB1Agent`:

Listing 1: Fragmento Central de la Clase `UCB1Agent` en Python

```
1 class UCB1Agent:
2     def __init__(self, n_arms=5, c=1.414):
3         self.n_arms = n_arms
4         self.c = c
5         self.counts = np.zeros(n_arms, dtype=int)
6         self.values = np.zeros(n_arms, dtype=float)
7         self.total_counts = 0
8
9     def select_action(self):
10         # 1. Probar cada brazo al menos una vez
```

```
11     for arm in range(self.n_arms):
12         if self.counts[arm] == 0:
13             return arm
14
15         # 2. Calcular cota UCB1 para cada brazo
16         ucb_values = self.values + self.c * np.sqrt(
17             (2 * np.log(self.total_counts)) / self.counts
18         )
19         return int(np.argmax(ucb_values))
20
21     def update(self, arm, reward):
22         self.total_counts += 1
23         self.counts[arm] += 1
24         # Actualización de media móvil incremental
25         n = self.counts[arm]
26         self.values[arm] += (reward - self.values[arm]) / n
```

## 7. Matriz de Resultados Operativos y Solución al Cliente

### 7.1. Matriz Comparativa Final

Tras ejecutar la simulación de 21 días (1,920 intervalos y 1,466 despachos), el Agente UCB1 convergió exitosamente hacia la política  $a_1$  (Flex\_14p\_15m). Los resultados operativos comparativos son los siguientes:

Tabla 3: Matriz Comparativa de Desempeño Operativo

| Métrica de Evaluación             | Regla Tradicional $a_0$ | Agente UCB1 ( $a_1$ ) | Mejora Impacto      |
|-----------------------------------|-------------------------|-----------------------|---------------------|
| Tiempo Promedio de Espera         | 38,4 min                | 16,2 min              | -57.8 % Ahorro      |
| Tiempo Máximo de Espera           | 84,5 min                | 28,1 min              | -66.7 % Ahorro      |
| Factor de Ocupación Vehicular     | 100,0 % (18/18)         | 77,7 % (14/18)        | Operación Eficiente |
| Alumnos Varados al Final del Día  | 142 alumnos             | 12 alumnos            | -91.5 % Varados     |
| Recompensa Promedio ( $\bar{Q}$ ) | 0,415                   | 0,692                 | +66.7 % Eficiencia  |

### 7.2. Respuestas Explicadas a las Preguntas del Cliente

1. ¿Conviene seguir esperando a que la combi se llene con 18 pasajeros? **No en horas valle.** Mantener la regla rígida de 18 pasajeros en horarios de baja demanda causa tiempos de espera superiores a 60 minutos.
2. ¿Cuál es el número mínimo razonable de pasajeros para salir? Un mínimo de **12 a 14 pasajeros** en hora valle. Permite mantener una ocupación superior al 77,7 % (rentable para el chófer) reduciendo la espera de los alumnos en un 57,8 %.
3. ¿En qué franjas conviene ser más flexible? En las **horas valle (10:00–12:00 y 16:00–18:00)**. En hora pico la combi se llena sola en 3 minutos sin necesidad de flexibilidad.



4. **¿Cuánto tiempo de espera se ahorra saliendo con 12 o 14 personas? Se ahorran en promedio 22.2 minutos por alumno por viaje.**



## 8. Guía de Defensa Técnica ante el Examen Ordinario/Final

**Pregunta 1:** ¿Por qué su modelo OLS tiene un  $R^2$  de 12.1 %?

**Respuesta:** .<sup>EI</sup>  $R^2 = 12,1 \%$  es el resultado estadístico real al modelar la cola inicial frente al tiempo de espera bajo demanda variable. Muestra que la cola explica una parte significativa del tiempo ( $p < 10^{-40}$ ), pero existe alta variabilidad entre horas pico y valle. Por eso OLS sirvió como modelo predictivo baseline y justificó implementar el Agente UCB1 para la toma de decisiones prescriptivas.”

**Pregunta 2:** ¿Cómo funciona el término de exploración en la fórmula UCB1?

**Respuesta:** .<sup>EI</sup> término  $\sqrt{\frac{2 \ln t}{N_j(t)}}$  actúa como un bonus de incertidumbre. Si una política se ha probado muy pocas veces ( $N_j(t)$  pequeño), el término aumenta drásticamente, obligando al agente a explorarla hasta estar seguro de su rendimiento.”

**Pregunta 3:** ¿Cómo justifican que la solución es viable para los chóferes?

**Respuesta:** ”Porque la política óptima elegida ( $a_1$ ) mantiene un factor de ocupación promedio del 77,7 % (14 de 18 pasajeros), garantizando que las combis no viajen vacías y cubran ampliamente sus costos operativos.”