



UNIVERSIDAD POLITÉCNICA DE PACHUCA
PROGRAMA EDUCATIVO DE INGENIERÍA EN SOFTWARE
ASIGNATURA: INTELIGENCIA ARTIFICIAL

MANUAL TÉCNICO Y TEÓRICO COMPLETO:
SISTEMA INTELIGENTE DE DESPACHO DE TRANSPORTE
UPP

Fundamentos Estadísticos MCO, Algoritmo UCB1 y Evaluación de Resultados

Información Institucional del Proyecto

Autores:	Emmanuel Islas Lozada Ximena Nathaly Angeles Sanchez
Grado y Grupo:	9º Cuatrimestre – Ingeniería en Software
Proyecto:	Sistema de Despacho Adaptativo mediante RL y OLS
Fecha de Entrega:	Agosto 2026
Versión de Release:	v1.0.0 Final



Índice

1. Definición del Problema Operativo y Contexto	2
1.1. El Desafío del Transporte Estudiantil en la UPP	2
1.2. El Conflicto de Intereses Operativo	2
1.3. Política Tradicional vs. Necesidad de Inteligencia Artificial	2
2. Generación del Dataset Simulado y Matemática de Arribos	3
2.1. Modelado de Arribos mediante Procesos de Poisson	3
2.2. Tasa de Arribo Variable ($\lambda(t)$) por Franja Horaria	3
2.3. Estructura de Variables del Dataset ('demand_dataset.csv')	3
3. Modelo de Regresión Lineal Simple MCO (OLS) y Evaluación de Supuestos	5
3.1. Formulación Matemática de Mínimos Cuadrados Ordinarios	5
3.2. Resultados del Modelo Ajustado (Modelo 2)	5
3.2.1. Interpretación de Parámetros e Indicadores	5
3.3. Evaluación Exhaustiva de los 5 Supuestos de Gauss-Markov	6
3.3.1. Justificación de la Transición de Regresión OLS a Aprendizaje por Refuerzo	7
4. Aprendizaje por Refuerzo Prescriptivo y Algoritmo UCB1	8
4.1. Formulación del Problema como Bandit Multibrazo (Multi-Armed Bandit) .	8
4.2. Espacio de Acciones (Brazos del Agente)	8
4.3. Función de Recompensa Multiobjetivo Normalizada $R \in [0, 1]$	8
4.4. El Algoritmo UCB1 (Upper Confidence Bound 1)	9
5. Resultados Experimentales y Evaluación Operativa	10
5.1. Matriz de Resultados Operativos (a_0 Tradicional vs. a_1 Agente UCB1) . . .	10
5.2. Respuestas Directas a las Preguntas Clave del Proyecto	10
6. Guía de Defensa Técnica ante el Comité Evaluador	12



6.1. Preguntas Frecuentes y Respuestas Argumentadas	12
---	----

1. Definición del Problema Operativo y Contexto

1.1. El Desafío del Transporte Estudiantil en la UPP

La Universidad Politécnica de Pachuca (UPP), ubicada en la zona metropolitana de Zempoala/Pachuca, cuenta con un flujo diario continuo de estudiantes que se desplazan desde y hacia puntos nodales clave, como la ruta **Puente Tuzos** y la **Central de Autobuses**. Durante las semanas ordinarias y de forma más crítica al cierre de cuatrimestre, la demanda de transporte experimenta fluctuaciones severas.

El servicio es operado por unidades de transporte tipo colectivo (çombis”) con una capacidad máxima estricta de $C = 18$ pasajeros por unidad.

1.2. El Conflicto de Intereses Operativo

El problema de despacho tradicional presenta una contradicción fundamental entre dos actores clave:

1. **El Concesionario/Conductor (Perspectiva Financiera):** Desea despachar la unidad **únicamente cuando está 100 % llena (18/18 pasajeros)**, maximizando el ingreso por vuelta y eliminando el costo de transportar asientos vacíos.
2. **El Estudiante/Usuario (Perspectiva de Servicio):** Desea abordar y salir lo más pronto posible. Si la combi espera a llenarse durante horarios de baja afluencia (”horas valle”), los tiempos de espera individuales pueden superar los 60 a 80 minutos, generando varamiento estudiantil y severa insatisfacción.

1.3. Política Tradicional vs. Necesidad de Inteligencia Artificial

La política operativa vigente (denominada en este estudio como política tradicional a_0) es rígida: la unidad permanece estacionada en la bahía de salida hasta acumular exactamente 18 pasajeros, sin importar la hora del día ni el tiempo transcurrido.

Para resolver esta ineficiencia se requiere un enfoque analítico en dos etapas:

- **Etapla Predictiva (Regresión Lineal OLS):** Para modelar cuantitativamente la física del tiempo de llenado en función de la cola de alumnos.
- **Etapla Prescriptiva (Aprendizaje por Refuerzo UCB1):** Para tomar la decisión adaptativa de cuándo despachar la unidad según las condiciones de demanda y horario.

2. Generación del Dataset Simulado y Matemática de Arribos

2.1. Modelado de Arribos mediante Procesos de Poisson

Para construir un dataset realista de 21 días de operación (equivalente al periodo crítico de fin de cuatrimestre), las llegadas de los estudiantes a las bahías de abordaje se modelaron como un **Proceso Estocástico de Poisson**.

La probabilidad de que arriben k estudiantes en un intervalo de tiempo t está dada por la función de masa de probabilidad:

$$P(N(t) = k) = \frac{(\lambda t)^k e^{-\lambda t}}{k!}, \quad k = 0, 1, 2, \dots \quad (1)$$

donde λ representa la tasa promedio de arribo de alumnos por minuto.

2.2. Tasa de Arribo Variable ($\lambda(t)$) por Franja Horaria

Un error común en simulaciones básicas es asumir una tasa constante λ . En el mundo real, la afluencia universitaria es altamente asimétrica. Por ello, se implementó una tasa dependiente del tiempo $\lambda(t)$:

Tabla 1: Parámetros de la Distribución Poisson por Franja Horaria

Franja Horaria	Tasa λ (alumnos/min)	Justificación Contextual
Hora Pico Matutina (07:00–09:00)	$\lambda_{\text{pico}} = 3,5$	Entrada masiva a clases de primera hora.
Hora Pico Vespertina (13:00–15:00)	$\lambda_{\text{pico}} = 3,5$	Cambio de turno y salida general de laboratorios.
Hora Valle (10:00–12:00 y 16:00–18:00)	$\lambda_{\text{valle}} = 1,2$	Flujo disperso de alumnos entre periodos libres.

2.3. Estructura de Variables del Dataset ('demand_dataset.csv')

La simulación generó un total de $n = 1,920$ registros de intervalos y 1,466 eventos de despacho estructurados en las siguientes variables clave:

Tabla 2: Diccionario de Datos del Dataset de Demanda y Despachos

Nombre de Columna	Tipo	Descripción Operativa
fecha	Date	Fecha de registro (periodo de 21 días).
hora_llegada	String	Hora exacta del arribo de la unidad a la bahía.
ruta	Factor	Ruta operada (<i>Puente Tuzos</i> o <i>Central</i>).
alumnos_esperando	Integer	Variable X : Alumnos presentes en la cola al llegar la combi.
pasajeros_salida	Integer	Pasajeros a bordo al momento de iniciar el viaje.
tiempo_espera_acum	Float	Variable Y : Minutos totales transcurridos desde el arribo hasta el despacho.
tipo_salida	Factor	Clasificación del despacho (<i>Llena</i> vs. <i>Parcial</i>).

3. Modelo de Regresión Lineal Simple MCO (OLS) y Evaluación de Supuestos

3.1. Formulación Matemática de Mínimos Cuadrados Ordinarios

La regresión lineal simple busca modelar la variable de respuesta Y (`minutos_para_llenar`) en función de la variable explicativa X (`alumnos_esperando`) mediante la ecuación:

$$Y_i = a + b \cdot X_i + e_i \quad (2)$$

donde a es el intercepto, b es la pendiente y e_i es el residuo o error del modelo para la observación i .

Los estimadores MCO minimizan la suma de errores al cuadrado ($\min \sum e_i^2$), calculándose como:

$$b = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}, \quad a = \bar{Y} - b\bar{X} \quad (3)$$

3.2. Resultados del Modelo Ajustado (Modelo 2)

Al ejecutar el script `02_train_regression.py` sobre las $n = 1,466$ observaciones filtradas del dataset, se obtuvo la siguiente ecuación ajustada:

Ecuación Empírica del Modelo OLS (Modelo 2)

$$\hat{Y} = 14,106834 - 2,539453 \cdot X \quad (4)$$

3.2.1. Interpretación de Parámetros e Indicadores

- **Intercepto** ($a = 14,11$ min): Si la combi llega a la bahía sin alumnos esperando en la cola ($X = 0$), el tiempo promedio estimado para completar la capacidad es de **14.11 minutos**.
- **Pendiente** ($b = -2,54$ min/alumno): Por cada alumno adicional presente en la cola inicial al momento de la llegada, el tiempo de espera restante se reduce en promedio **2.54 minutos**.
- **Coefficiente de Determinación** ($R^2 = 0,1210$): El modelo explica el **12.1 %** de la varianza total del tiempo de espera.
- **Significancia Estadística** ($p = 5,83 \times 10^{-43}$): Con un p -valor extremadamente cercano a cero ($p < 0,0001$), se rechaza categóricamente la hipótesis nula $H_0 : b = 0$. Se concluye con un **nivel de confianza** $> 99,99 \%$ que la relación entre ambas variables es real y estadísticamente significativa.

Aclaración sobre el "74%" de la Plantilla de la Bitácora

Es crucial distinguir entre los datos reales del modelo y los ejemplos ilustrativos. La cifra de $R^2 = 0,74$ (74 %) mencionada en la página 5 del documento de instrucciones de la asignatura correspondía únicamente a una **tabla de ejemplo hipotética** provista como guía para el llenado de la bitácora de IA. En datos simulados reales con variabilidad en horas valle, un $R^2 = 12,1$ % con significancia $p < 10^{-40}$ es el resultado empírico científicamente correcto.

3.3. Evaluación Exhaustiva de los 5 Supuestos de Gauss-Markov

Para determinar la confiabilidad teórica del modelo OLS, se evaluaron formalmente las 5 hipótesis fundamentales del teorema de Gauss-Markov sobre los residuos $e_i = Y_i - \hat{Y}_i$:

Tabla 3: Resumen del Diagnóstico de los 5 Supuestos de Gauss-Markov

Supuesto MCO	Resultado	Explicación Técnica y Diagnóstico
1. Linealidad	Cumple parcialmente	Tendencia lineal general válida, aunque la prueba de curvatura muestra un componente cuadrático leve ($F = 25,86, p < 0,001$).
2. Independencia de Errores	Riesgo moderado	Presencia de autocorrelación positiva leve ($DW \approx 0,17$) debido al fenómeno de arribos estudiantiles en ráfagas o grupos de amigos (. ^{en} bolas”).
3. Homocedasticidad	Falla	Varianza no constante (Heterocedasticidad, Breusch-Pagan $p < 0,05$). En hora pico el error es de $\pm 1 - 2$ min, mientras que en hora valle la dispersión alcanza ± 10 min.
4. Esperanza Nula	Cumple 100 %	Por definición matemática de MCO ($\sum e_i = 0$), el promedio teórico y numérico de los errores es exactamente cero.
5. Normalidad de Residuos	Riesgo moderado	Forma acampanada adecuada en la zona central con colas ligeramente más pesadas debido a la dispersión de las horas valle.

3.3.1. Justificación de la Transición de Regresión OLS a Aprendizaje por Refuerzo

La falla en la homocedasticidad y la baja varianza explicada ($R^2 = 12,1\%$) demuestran que un modelo de Regresión Lineal por sí solo es **predictivo pero no prescriptivo**. OLS nos indica el tiempo promedio estimado, pero no puede decidir cuál es la política de despacho óptima bajo escenarios estocásticos cambiantes. Esto justifica plenamente el uso del algoritmo **UCB1** en el siguiente bloque del proyecto.

4. Aprendizaje por Refuerzo Prescriptivo y Algoritmo UCB1

4.1. Formulación del Problema como Bandit Multibrazo (Multi-Armed Bandit)

Para solucionar las decisiones de despacho en tiempo real, el problema se formuló como un marco de **Bandits Multibrazo**, donde un agente autónomo interactúa con el entorno de la terminal universitaria probando diferentes políticas de salida y aprendiendo cuáles generan el mayor rendimiento operativo.

4.2. Espacio de Acciones (Brazos del Agente)

El agente dispone de un conjunto de $K = 5$ políticas de despacho discretas (brazos a_0 a a_4):

Tabla 4: Catálogo de Políticas de Despacho (Brazos de Selección)

Brazo	Nombre de la Política	Regla Operativa de Salida
a_0	Llenado_Estricto_18p	Salir únicamente cuando la unidad acumule 18 pasajeros (Política Tradicional).
a_1	Flex_14p_15m	Salir si hay ≥ 14 pasajeros O si transcurrieron 15 minutos de espera.
a_2	Flex_12p_25m	Salir si hay ≥ 12 pasajeros O si transcurrieron 25 minutos de espera.
a_3	Flex_10p_35m	Salir si hay ≥ 10 pasajeros O si transcurrieron 35 minutos de espera.
a_4	Max_Espera_45m	Esperar máximo 45 minutos o hasta alcanzar un mínimo razonable de 8 alumnos.

4.3. Función de Recompensa Multiobjetivo Normalizada $R \in [0, 1]$

Para evaluar la calidad de cada despacho, se diseñó una función de recompensa escalar normalizada que penaliza los tres grandes dolores del sistema: tiempo de espera, alumnos varados y asientos vacíos.

La recompensa no normalizada se calcula como:

$$R_{\text{raw}} = -(w_1 \cdot \text{espera_prom} + w_2 \cdot \text{alumnos_varados} + w_3 \cdot \text{asientos_vacios}) \quad (5)$$

con pesos ponderados $w_1 = 0,4$, $w_2 = 0,4$ y $w_3 = 0,2$.

Aplicando escalamiento Min-Max e inversión de polaridad para restringir el valor al rango $R \in [0, 1]$ (donde 1,0 representa el despacho perfecto y 0,0 el peor desempeño posible):

$$R_i = 1,0 - \left(0,4 \cdot \frac{\text{espera}_i}{60} + 0,4 \cdot \frac{\text{varados}_i}{30} + 0,2 \cdot \frac{\text{vacios}_i}{18} \right) \quad (6)$$

4.4. El Algoritmo UCB1 (Upper Confidence Bound 1)

El algoritmo UCB1 resuelve el dilema clásico entre **Exploración** (probar brazos poco conocidos) y **Explotación** (seleccionar el brazo con mejor recompensa promedio observada hasta el momento).

En cada despacho t , el agente selecciona la acción $a(t)$ que maximiza la cota superior de confianza:

$$a(t) = \arg \max_{j \in \{0, \dots, K-1\}} \left[\bar{Q}_j(t) + c \sqrt{\frac{2 \ln t}{N_j(t)}} \right] \quad (7)$$

donde:

- $\bar{Q}_j(t)$: Recompensa promedio obtenida por el brazo j hasta el instante t (término de explotación).
- $N_j(t)$: Número de veces que se ha seleccionado el brazo j hasta el instante t .
- t : Número total de despachos realizados por todas las políticas.
- c : Constante de exploración (configurada en $c = 1,0$).
- $\sqrt{\frac{2 \ln t}{N_j(t)}}$: Término de incertidumbre (bonus de exploración). Si un brazo no se ha probado casi nunca, $N_j(t)$ es pequeño y el término crece, forzando al agente a explorar dicho brazo.

5. Resultados Experimentales y Evaluación Operativa

5.1. Matriz de Resultados Operativos (a_0 Tradicional vs. a_1 Agente UCB1)

Tras simular las 3 semanas de operación crítica (1,920 intervalos y 1,466 despachos), el agente UCB1 convergió de forma consistente hacia la política a_1 (Flex_14p_15m). Los resultados cuantitativos se resumen a continuación:

Tabla 5: Matriz de Resultados Comparativos de Operación

Métrica de Evaluación	Política Tradicional a_0	Agente UCB1 (a_1)	Mejora Alcanzada
Tiempo Promedio de Espera	38,4 min	16,2 min	-57.8 % Ahorro
Tiempo Máximo de Espera	84,5 min	28,1 min	-66.7 % Ahorro
Factor de Ocupación Vehicular	100,0 % (18/18)	77,7 % (14/18)	Equilibrio Eficiente
Alumnos Varados al Final del Día	142 alumnos	12 alumnos	-91.5 % Varados
Recompensa Promedio ($\bar{Q}$)	0,415	0,692	+66.7 % Eficiencia

5.2. Respuestas Directas a las Preguntas Clave del Proyecto

Con base en los datos generados y validados, se responden formalmente los cuestionamientos operativos planteados en el proyecto:

1. **¿Conviene seguir esperando a que la combi se llene con 18 pasajeros? No en horas valle.** Esperar 18 alumnos en horarios de baja afluencia produce tiempos de espera individuales superiores a 60 minutos, colapsando la calidad del servicio.
2. **¿Cuál es el número mínimo razonable de pasajeros para salir?** Un mínimo de **12 a 14 pasajeros** en hora valle es la franja óptima. Preserva un factor de ocupación superior al 77,7 % (garantizando rentabilidad económica) mientras reduce la espera en un 57,8 %.

3. **¿En qué franjas conviene ser más flexible?** Exclusivamente en las **franjas valle (10:00–12:00 y 16:00–18:00)**. En horas pico (07:00–09:00 y 13:00–15:00), la unidad se llena de forma natural en menos de 3 a 5 minutos, por lo que la regla de 18 se cumple automáticamente.
4. **¿Cuánto tiempo de espera se reduce saliendo con 12 o 14 personas?** Se ahorran en promedio **22.2 minutos por alumno por viaje** (pasando de 38,4 min a 16,2 min en promedio).

6. Guía de Defensa Técnica ante el Comité Evaluador

6.1. Preguntas Frecuentes y Respuestas Argumentadas

Pregunta 1: ¿Por qué usaron un modelo $R^2 = 12.1\%$ en lugar de buscar un R^2 más alto?

Respuesta: El $R^2 = 12.1\%$ refleja con precisión matemática la realidad física del transporte universitario: el número de alumnos en la cola explica significativamente una parte del tiempo ($p < 10^{-40}$), pero la alta variabilidad entre horas pico y horas valle introduce ruido estocástico no lineal. En lugar de forzar una regresión lineal irreal, usamos OLS como baseline predictivo y justificamos el uso de Inteligencia Artificial Prescriptiva (Agente UCB1), que sí resuelve la variabilidad en tiempo real.”

Pregunta 2: ¿Cuál es la diferencia entre el modelo predictivo (OLS) y el prescriptivo (UCB1)?

Respuesta: ”La Regresión OLS nos indica *qué va a pasar en promedio* (predicción). El Agente UCB1 toma esa información y *decide qué acción tomar* (prescripción), evaluando dinámicamente si conviene salir o esperar para maximizar la recompensa multiobjetivo.”

Pregunta 3: ¿Por qué eligieron la política a1 (Flex_14p_15m) como la mejor?

Respuesta: ”Porque demostró estadísticamente ser el punto de equilibrio óptimo. Reduce la espera en un 57,8% y los alumnos varados en un 91,5%, manteniendo una ocupación del 77,7%, lo que asegura que el concesionario no opere con pérdidas.”