



UNIVERSIDAD POLITÉCNICA DE PACHUCA

Ingeniería en Software – Inteligencia Artificial

Proyecto Final de Simulación y Aprendizaje por Refuerzo



Optimización de Rutas UPP via UCB1 Multi-Armed Bandit

Modelo Predictivo OLS y Tomador de Decisiones Adaptativo para Despacho

Integrantes del Equipo:

Angeles Sanchez Ximena Nathaly | **Islas Lozada Emmanuel**

Asignatura: Inteligencia Artificial – Periodo Mayo–Agosto 2026

“Aprender directamente de la interacción con el entorno es el principio fundamental del comportamiento inteligente.”

— **Richard S. Sutton**

Padre del Aprendizaje por Refuerzo Moderno y Coautor de *Reinforcement Learning:
An Introduction*

Agenda General: Parte I

Diagnóstico, Dataset y Regresión OLS

1. **Problema Operativo UPP:** Cuello de botella en transporte estudiantil.
2. **Dataset Simulado:** Proceso estocástico Poisson (λ variable).
3. **Modelo Predictivo OLS:** Regresión lineal $Y = a + bX$.
4. **Diagnóstico de Supuestos MCO:** Pruebas de Linealidad, DW y Breusch-Pagan.

Agenda General: Parte II

Prescripción, Algoritmo UCB1 y Resultados

1. **Algoritmo UCB1:** Agente Multi-Armed Bandit para despacho dinámico.
2. **Evaluación Experimental:** Comparativa directa a_0 vs UCB1.
3. **Respuestas Operativas:** Solución a las preguntas clave del negocio.
4. **Bitácora de IA & Conclusiones:** Evaluación crítica con Gemini y Codex.

Contexto Operativo del Transporte UPP

La Dinámica del Servicio

- ▶ **Rutas Clave Monitoreadas:** *Puente de Tuzos y San Agustín.*
- ▶ **Capacidad del Vehículo:** Combis urbanas con capacidad de **18 pasajeros.**
- ▶ **Regla Tradicional de Despacho (a_0):** Salir únicamente cuando el vehículo está al 100% de capacidad (**18 alumnos**).

El Cuello de Botella en Horas Valle

Ineficiencia Severa de la Regla Rígida a_0

- ▶ **Horas Pico (07:00–09:00, 13:00–15:00):** La combi se llena en menos de 5 minutos.
- ▶ **Horas Valle (10:00–12:00, 16:00–18:00):** La llegada de alumnos cae drásticamente.
- ▶ **Tiempos de Espera Extremos:** Los estudiantes deben esperar de **60 a 84 minutos** dentro o fuera de la unidad.

La Pregunta Central de Negocio

Reto de Optimización Multiobjetivo

¿Es posible definir una política de despacho flexible que reduzca el tiempo de espera estudiantil en más del 50% sin mermar la rentabilidad económica del transporte?

Dataset Simulado: Proceso Estocástico Poisson

Modelado de Llegadas de Estudiantes

Proceso Poisson homogéneo por franjas horarias:

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}$$

- ▶ **Tasa en Hora Pico:** $\lambda_{\text{pico}} = 3.5$ alumnos / 15 min.
- ▶ **Tasa en Hora Valle:** $\lambda_{\text{valle}} = 1.2$ alumnos / 15 min.
- ▶ **Volumen del Dataset:** 21 días evaluados (1,466 despachos reales).

Estructura del Dataset: Variables de Entrada

Variables Predictoras y de Contexto Simulado

Variable Clave	Descripción Operativa
<code>fecha, hora_intervalo</code>	Registro temporal del despacho en la terminal.
<code>ruta</code>	Indicador de ruta (<i>Puente de Tuzos / San Agustín</i>).
<code>alumnos_esperando</code>	Cola inicial al llegar la unidad (X).

Estructura del Dataset: Variables de Respuesta

Variables de Salida y Tiempos de Servicio

Variable Clave	Descripción Operativa
<code>pasajeros_al_salir</code>	Número de pasajeros a bordo al salir.
<code>tiempo_espera_acum</code>	Tiempo total transcurrido en minutos (Y).
<code>tipo_salida</code>	Salida Llena (18 pax) / Salida Parcial (< 18 pax).

Modelo Predictivo OLS (Regresión Lineal Simple)

Formulación Matemática MCO

Evaluación de la relación entre cola inicial (X) y tiempo de salida (Y):

$$Y_i = a + b \cdot X_i + e_i$$

Estimadores de Mínimos Cuadrados Ordinarios:

$$b = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sum (X_i - \bar{X})^2}, \quad a = \bar{Y} - b\bar{X}$$


Resultados de la Regresión Lineal OLS

Ecuación Estimada del Tiempo de Espera

$$\hat{Y} = 14.1068 - 2.5395 \cdot X$$

- ▶ **Intercepto** ($a = 14.11$ min): Espera estimada sin cola inicial ($X = 0$).
- ▶ **Pendiente** ($b = -2.54$ min/pax): Cada alumno presente al llegar reduce la espera en 2.54 minutos.
- ▶ **Significancia Estadística**: $p = 5.83 \times 10^{-43} < 0.001$, $F = 201.8$.

Gráfica del Modelo OLS Ajustado



Diagnóstico de Supuestos OLS: Independencia y Linealidad

1. Independencia (Durbin-Watson)

$DW = 1.6002$: Dentro del rango aceptable $[1.5, 2.5]$, confirmando independencia entre despachos consecutivos.

2. Linealidad


Test F cuadrático $p < 0.001$. Se observa ligera curvatura en valle por el límite rígido de 18 asientos.

Diagnóstico de Supuestos OLS: Homocedasticidad

3. Prueba de Breusch-Pagan

- ▶ **Resultado del Test:** $LM = 25.79, p < 0.001$.
- ▶ **Diagnóstico:** Existe heterocedasticidad (varianza de residuos no constante) debido a la volatilidad entre franjas pico y valle.
- ▶ **Implicación Práctica:** El modelo OLS sigue siendo un estimador insesgado de la tendencia central para el agente UCB1.

Evaluación de Heterocedasticidad en Residuos



Aprendizaje por Refuerzo: Algoritmo UCB1

Formulación Matemática del Agente UCB1

El agente selecciona la regla A_t mediante la Cota Superior de Confianza:

$$A_t = \arg \max_a \left[\bar{Q}_t(a) + c \sqrt{\frac{\ln t}{N_t(a)}} \right]$$

- ▶ **Explotación** ($\bar{Q}_t(a)$): Recompensa promedio histórica del brazo a .
- ▶ **Exploración** ($c \sqrt{\frac{\ln t}{N_t(a)}}$): Bonus de incertidumbre para probar reglas menos frecuentadas ($c = \sqrt{2}$).

Catálogo de Políticas: Brazos Dinámicos (a_0, a_1, a_2)

Políticas Tradicionales y Dinámicas de Despacho

Brazo	Identificador	Regla de Despacho	Tipo de Regla
a_0	FullOnly	Salir únicamente con 18 pasajeros.	Rígida / Tradicional
a_1	Flex_14p_15m	Salir con ≥ 14 pax O tras 15 min.	Ganador UCB1
a_2	Flex_12p_25m	Salir con ≥ 12 pax O tras 25 min.	Dinámica Moderada

Catálogo de Políticas: Brazos Conservadores (a_3, a_4)

Políticas con Alto Umbral de Espera en Hora Valle

Brazo	Identificador	Regla de Despacho	Tipo de Regla
a_3	Flex_10p_35m	Salir con ≥ 10 pax O tras 35 min.	Dinámica Valle
a_4	Flex_8p_45m	Salir con ≥ 8 pax O tras 45 min.	Límite Máximo

Función de Recompensa Normalizada

Penalización Multiobjetivo y Normalización Min-Max

$$P_t = 0.4 \cdot \text{espera} + 0.4 \cdot \text{dejados} + 0.2 \cdot \text{vacíos}$$

Escalamiento invertido en el rango $R_t \in [0, 1]$:

$$R_t = 1 - \frac{P_t - P_{\min}}{P_{\max} - P_{\min}}$$


- ▶ $R_t \rightarrow 1$: Despacho óptimo (mínima espera y alta ocupación).
- ▶ $R_t \rightarrow 0$: Despacho ineficiente.

Convergencia y Aprendizaje del Agente UCB1

Selección Óptima del Brazo a_1



- ▶ El agente UCB1 convergió consistentemente al brazo a_1 (Flex_14p_15m).
- ▶ Alcanzó la máxima recompensa promedio esperada ($\bar{Q} = 0.692$).
- ▶ Mantiene llenado rápido en pico y limita la espera a máximo 15 min en valle.

Evolución de Recompensa del Agente UCB1



Comparativa Experimental: Política Tradicional vs UCB1

Performance Benchmark: Traditional Baseline vs UCB1 Agent



Matriz de Resultados: Tiempos de Espera

Reducción de Tiempos de Espera Estudiantil

Métrica de Evaluación	Regla Tradicional a_0	Agente UCB1 (a_1)	Mejora Alcanzada
Tiempo Promedio de Espera	38.4 min	16.2 min	-57.8% Ahorro
Tiempo Máximo de Espera	84.5 min	28.1 min	-66.7% Ahorro

Matriz de Resultados: Ocupación y Eficiencia Global

Ocupación Vehicular, Alumnos Varados y Recompensa $\bar{Q}$

Métrica de Evaluación	Regla Tradicional a_0	Agente UCB1 (a_1)	Mejora Alcanzada
Factor de Ocupación	100.0% (18/18)	77.7% (14/18)	Equilibrio Eficiente
Alumnos Varados	142 alumnos	12 alumnos	-91.5% Varados
Recompensa Promedio ($\bar{Q}$)	0.415	0.692	+66.7% Eficiencia

Respuestas Operativas Clave: Ocupación y Umbral

1. ¿Conviene esperar cupo de 18 pasajeros?

No en horas valle. Esperar 18 alumnos produce demoras desmedidas de más de 60 minutos, colapsando la satisfacción estudiantil.

2. Mínimo razonable de ocupación para salir

Salir con **12 a 14 pasajeros** en hora valle reduce la espera en un **57.8%** preservando una rentabilidad superior al 77%.

Respuestas Operativas Clave: Flexibilidad y Ahorro

3. ¿En qué franjas ser más flexible?

Exclusivamente en franjas valle (10:00–12:00 y 16:00–18:00). En hora pico la unidad se llena en menos de 5 minutos.

4. Ahorro de tiempo por alumno

Se ahorran en promedio **22.2 minutos por alumno por viaje** frente a la regla rígida tradicional a_0 .

Evidencia de Bitácora IA: ChatGPT y GitHub Copilot

Evaluación Crítica de Simulación y Regresión

Herramienta	Tema Evaluado	Solicitud / Pregunta	Verificación y Aprendizaje
ChatGPT	Simulación	Llegadas por intervalo en Python.	Ajusté λ variable por franja (Pico=3.5, Valle=1.2).
Copilot	Regresión	Código de ajuste OLS.	Corregí formato 2D exigido por scikit-learn.

Evidencia de Bitácora IA: Google Gemini y OpenAI Codex

Evaluación Crítica de Supuestos MCO y Algoritmo UCB1

Herramienta	Tema Evaluado	Solicitud / Pregunta	Verificación y Aprendizaje
Gemini	Supuestos MCO	Pruebas Breusch-Pagan y DW.	Validé que la heterocedasticidad no sesga coeficientes.
Codex	Algoritmo UCB1	Recompensa multiobjetivo.	Implementé min-max scaling invertido $[0, 1]$.

Conclusiones y Trabajo Futuro

Conclusiones Principales

- ▶ **Aporte Predictivo OLS:**
Confirmó significancia estadística ($b = -2.54, p < 0.001$).
- ▶ **Aporte Prescriptivo UCB1:**
Logró un ahorro del **57.8%** en tiempo de espera.

Trabajo Futuro

- ▶ **Contextual Bandits (LinUCB):** Incorporar clima y eventos en tiempo real.
- ▶ **Deep RL (DQN):** Control continuo de flota en múltiples terminales.

“La toma de decisiones inteligente consiste en encontrar alternativas satisfactorias en un entorno complejo e incierto.”

— **Herbert A. Simon**

Premio Nobel de Economía y Pionero de la Inteligencia Artificial

¡Muchas Gracias por su Atención!

¿Preguntas o Comentarios?

Angeles Sanchez Ximena Nathaly & Islas Lozada Emmanuel