



UNIVERSIDAD POLITÉCNICA DE PACHUCA

Ingeniería en Software – Inteligencia Artificial

Proyecto Final de Simulación y Aprendizaje por Refuerzo



Optimización de Rutas UPP via UCB1 Multi-Armed Bandit

Modelo Predictivo OLS y Tomador de Decisiones Adaptativo para Despacho

Integrantes del Equipo:

Angeles Sanchez Ximena Nathaly (Círculo)
(Cuadrado)

Islas Lozada Emmanuel

Asignatura: Inteligencia Artificial – Periodo Mayo–Agosto 2026

“Aprender directamente de la interacción con el entorno es el principio fundamental del comportamiento inteligente.”

— **Richard S. Sutton**

Padre del Aprendizaje por Refuerzo Moderno y Coautor de *Reinforcement Learning:
An Introduction*



Agenda General: Parte I

Diagnóstico, Dataset y Regresión OLS

1. **Problema Operativo UPP:** Cuello de botella en transporte estudiantil.
2. **Dataset Simulado:** Proceso estocástico Poisson (λ variable).
3. **Modelo Predictivo OLS:** Regresión lineal $Y = a + bX$.
4. **Diagnóstico de Supuestos MCO:** Pruebas de Linealidad, DW y Breusch-Pagan.



Agenda General: Parte II

Prescripción, Algoritmo UCB1 y Resultados

1. **Algoritmo UCB1:** Agente Multi-Armed Bandit para despacho dinámico.
2. **Evaluación Experimental:** Comparativa directa a_0 vs UCB1.
3. **Respuestas Operativas:** Solución a las preguntas clave del negocio.
4. **Bitácora de IA & Conclusiones:** Evaluación crítica con Gemini y Codex.



Arquitectura General del Sistema UPP Route RL



Contexto Operativo del Transporte UPP

La Dinámica del Servicio

- ▶ **Rutas Clave Monitoreadas:** *Las Vías* y *Puente de Tuzos*.
- ▶ **Capacidad del Vehículo:** Combis urbanas con capacidad de **18 pasajeros**.
- ▶ **Regla Tradicional de Despacho (a_0):** Salir únicamente cuando el vehículo está al 100% de capacidad (**18 alumnos**).

El Cuello de Botella en Horas Valle

Ineficiencia Severa de la Regla Rígida a_0

- ▶ **Horas Pico (07:00–09:00, 11:00–13:00):** La combi se llena rápidamente en menos de **5 minutos**.
- ▶ **Horas Valle (10:00–11:00, 14:00–16:00):** La llegada de alumnos cae drásticamente.
- ▶ **Límite Máximo de Espera:** Los estudiantes llegan a esperar hasta el tope tolerado de **30 minutos** antes de forzar el despacho.



La Pregunta Central de Negocio

Reto de Optimización Multiobjetivo

¿Es posible definir una política de despacho flexible que reduzca el tiempo de espera estudiantil sin mermar la rentabilidad económica del transporte?



Dataset Simulado: Proceso Estocástico Poisson

Modelado de Llegadas de Estudiantes

Proceso Poisson homogéneo por franjas horarias:

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}$$

- ▶ **Tasa en Hora Pico:** $\lambda_{\text{pico}} = 3.5$ alumnos / 15 min.
- ▶ **Tasa en Hora Valle:** $\lambda_{\text{valle}} = 1.2$ alumnos / 15 min.
- ▶ **Volumen del Dataset:** 21 días evaluados (1,788 despachos reales).

Estructura del Dataset: Variables de Entrada

Variables Predictoras y de Contexto Simulado

Variable Clave	Descripción Operativa
<code>fecha, hora</code>	Registro temporal del despacho en la terminal.
<code>ruta</code>	Indicador de ruta (<i>Las Vías / Puente Tuzos</i>).
<code>alumnos_esperando</code>	Cola inicial al llegar la unidad (X).

Estructura del Dataset: Variables de Respuesta

Variables de Salida y Tiempos de Servicio

Variable Clave	Descripción Operativa
<code>pasajeros_al_salir</code>	Número de pasajeros a bordo al salir.
<code>tiempo_espera_acum</code>	Tiempo total transcurrido en minutos (Y).
<code>tipo_salida</code>	Salida Llena (18 pax) / Salida Parcial (< 18 pax).

Modelo Predictivo OLS (Regresión Lineal Simple)

Formulación Matemática MCO

Evaluación de la relación entre cola inicial (X) y tiempo de salida (Y):

$$Y_i = a + b \cdot X_i + e_i$$

Estimadores de Mínimos Cuadrados Ordinarios:

$$b = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sum (X_i - \bar{X})^2}, \quad a = \bar{Y} - b\bar{X}$$


Resultados de la Regresión Lineal OLS

Ecuación Estimada del Tiempo de Espera

$$\hat{Y} = 15.7061 - 2.8694 \cdot X$$

- ▶ **Intercepto** ($a = 15.71$ min): Espera estimada sin cola inicial ($X = 0$).
- ▶ **Pendiente** ($b = -2.87$ min/pax): Cada alumno presente al llegar reduce la espera en 2.87 minutos.
- ▶ **Varianza Explicada** ($R^2 = 0.2177$): Explica el 21.77% de la variabilidad del tiempo.
- ▶ **Significancia Estadística**: $p = 2.59 \times 10^{-97} < 0.001$ ($n = 1,788$).

Gráfica del Modelo OLS Ajustado



Diagnóstico de Supuestos OLS: Independencia y Linealidad

1. Independencia (Durbin-Watson)

$DW = 1.3142$: En rango aceptable de independencia para series de despachos consecutivos.

2. Linealidad (Test F Cuadrático)

Test F cuadrático $F = 62.81, p < 0.001$. Confirma la relación lineal entre cola inicial y tiempo de espera.




Diagnóstico de Supuestos OLS: Homocedasticidad y Normalidad

3. Pruebas de Breusch-Pagan y Shapiro-Wilk

- ▶ **Breusch-Pagan** ($LM = 145.58, p < 0.001$): Heterocedasticidad por volatilidad de flujo entre hora pico y valle.
- ▶ **Shapiro-Wilk** ($W = 0.6803, p < 0.05$): Residuos no normales por el límite máximo de espera (30 min).
- ▶ **Implicación Práctica**: El estimador OLS se mantiene como estimador insesgado BLUE para el modelo prescriptivo.

Evaluación de Heterocedasticidad en Residuos



Aprendizaje por Refuerzo: Algoritmo UCB1

Formulación Matemática del Agente UCB1

El agente selecciona la regla A_t mediante la Cota Superior de Confianza:

$$A_t = \arg \max_a \left[\bar{Q}_t(a) + c \sqrt{\frac{\ln t}{N_t(a)}} \right]$$

- ▶ **Explotación** ($\bar{Q}_t(a)$): Recompensa promedio histórica del brazo a .
- ▶ **Exploración** ($c \sqrt{\frac{\ln t}{N_t(a)}}$): Bonus de incertidumbre para probar reglas menos frecuentadas ($c = \sqrt{2}$).

Catálogo de Políticas: Brazos Dinámicos (a_0, a_1, a_2)

Políticas Tradicionales y Dinámicas de Despacho

Brazo	Identificador	Regla de Despacho	Tipo de Regla
a_0	Full0only	Salir únicamente con 18 pasajeros.	Rígida / Tradicional
a_1	Flex_14p_15m	Salir con ≥ 14 pax O tras 15 min.	Dynamic Flex
a_2	Flex_12p_20m	Salir con ≥ 12 pax O tras 20 min.	Ganador UCB1

Catálogo de Políticas: Brazos Conservadores (a_3, a_4)

Políticas con Alto Umbral de Espera en Hora Valle

Brazo	Identificador	Regla de Despacho	Tipo de Regla
a_3	Flex_10p_25m	Salir con ≥ 10 pax O tras 25 min.	Dinámica Valle
a_4	Flex_8p_30m	Salir con ≥ 8 pax O tras 30 min.	Límite Máximo (30 min)

Función de Recompensa Normalizada

Penalización Multiobjetivo y Normalización Min-Max

$$P_t = 0.4 \cdot \text{espera} + 0.4 \cdot \text{dejados} + 0.2 \cdot \text{vacíos}$$

Escalamiento invertido en el rango $R_t \in [0, 1]$:

$$R_t = 1 - \frac{P_t - P_{\min}}{P_{\max} - P_{\min}}$$

- ▶ $R_t \rightarrow 1$: Despacho óptimo (mínima espera y alta ocupación).
- ▶ $R_t \rightarrow 0$: Despacho ineficiente.

Convergencia y Aprendizaje del Agente UCB1

Selección Eficiente entre Brazos de Despacho

- ▶ El agente UCB1 favoreció la política a_2 (Flex_12p_20m) y a_0 (Fullonly).
- ▶ Alcanzó una recompensa promedio acumulada de $\bar{Q} = 0.8081$.
- ▶ Mantiene llenado completo en hora pico y garantiza un límite estricto de **30.0 min** de espera.




Distribucion de Seleccion de Brazos

Desglose de Decisiones del Agente durante 1,788 Despachos

Brazo	Regla Operativa	Elecciones	Porcentaje	Estimación
a_0	Tradicional (18 pax)	384	21.5%	$\bar{Q}_0 = 0.815$
a_1	Flex (≥ 14 pax / 15 min)	359	20.1%	$\bar{Q}_1 = 0.808$
a_2	Flex (≥ 12 pax / 20 min)	394	22.0%	$Q_2 = 0.818$ (Óptimo)
a_3	Flex (≥ 10 pax / 25 min)	331	18.5%	$\bar{Q}_3 = 0.800$
a_4	Salida Máxima (< 10 pax / 30 min)	320	17.9%	$\bar{Q}_4 = 0.797$

Evolución de Recompensa del Agente UCB1




Comparativa Experimental: Política Tradicional vs UCB1

Benchmark de Desempeño: Política Tradicional vs Agente UCB1

Tiempo de Espera Promedio en Despacho



Tiempo de Espera Máximo en Despacho



Matriz de Resultados: Tiempos de Espera

Control y Limitación de Tiempos de Espera Estudiantil

Métrica de Evaluación	Regla Tradicional a_0	Agente UCB1	Diagnóstico Operativo
Tiempo Promedio de Espera	10.6 min	11.3 min	Fluidez Promedio
Tiempo Máximo de Espera	30.0 min	30.0 min	Tope Estricto Garantizado

Matriz de Resultados: Ocupación y Eficiencia Global

Ocupación Vehicular y Eficiencia del Agente

Métrica de Evaluación	Regla Tradicional a_0	Agente UCB1	Diagnóstico Operativo
Despachos Totales	1,604 viajes	1,664 viajes	+60 Salidas Frecuentes
Asientos Vacíos Promedio	0.0 pax	0.1 pax	Ocupación >99%
Recompensa Promedio ($\bar{Q}$)	N/A	0.8081	Alta Eficiencia

Respuestas Operativas Clave: Ocupación y Umbral

1. ¿Conviene esperar cupo de 18 pasajeros?

En hora pico sí, pero con tope de 30 min en hora valle. No se debe permitir que el vehículo permanezca estacionado más de 30 minutos sin salir.

2. Mínimo razonable de ocupación para salir

Salir con **12 a 14 pasajeros** en hora valle cuando la espera alcanza los 20 minutos equilibra ocupación y tiempo.



Respuestas Operativas Clave: Flexibilidad y Ahorro

3. ¿En qué franjas ser más flexible?

Exclusivamente en franjas valle (10:00–11:00 y 14:00–16:00). En hora pico la unidad se llena en menos de 5 minutos.

4. Control del Tiempo Máximo de Espera

La regla flexible garantiza que ****ningún** estudiante supere los 30 minutos de espera******, eliminando retrasos extremos.



Bitácora IA: ChatGPT y GitHub Copilot

Evaluación Crítica de Simulación y Regresión

Herramienta	Tema Evaluado	Solicitud / Pregunta	Verificación y Aprendizaje
ChatGPT	Simulación	Llegadas por intervalo en Python.	Ajusté λ variable por franja (Pico=3.5, Valle=1.2).
Copilot	Regresión	Código de ajuste OLS.	Corregí formato 2D exigido por scikit-learn.

Bitácora IA: Google Gemini y OpenAI Codex

Evaluación Crítica de Supuestos MCO y Algoritmo UCB1

Herramienta	Tema Evaluado	Solicitud / Pregunta	Verificación y Aprendizaje
Gemini	Supuestos MCO	Pruebas Breusch-Pagan y DW.	Validé que la heterocedasticidad no sesga coeficientes.
Codex	Algoritmo UCB1	Recompensa multiobjetivo.	Implementé min-max scaling invertido $[0, 1]$.

Conclusiones y Trabajo Futuro

Conclusiones Principales

- ▶ **Aporte Predictivo OLS:**
Confirmó significancia estadística ($b = -2.87, p < 0.001$).
- ▶ **Aporte Prescriptivo UCB1:**
Garantizó el tope de **30 min de espera** manteniendo ocupación >99%.

Trabajo Futuro

- ▶ **Contextual Bandits (LinUCB):** Incorporar clima y eventos en tiempo real.
- ▶ **Deep RL (DQN):** Control continuo de flota en múltiples terminales.

“La toma de decisiones inteligente consiste en encontrar alternativas satisfactorias en un entorno complejo e incierto.”

— **Herbert A. Simon**

Premio Nobel de Economía y Pionero de la Inteligencia Artificial

¡Muchas Gracias por su Atención!

¿Preguntas o Comentarios?

Angeles Sanchez Ximena Nathaly (Círculo Púrpura) & Islas Lozada Emmanuel
(Cuadrado Cian)