



UNIVERSIDAD POLITÉCNICA DE PACHUCA

Ingeniería en Software – Inteligencia Artificial

Proyecto Final de Simulación y Aprendizaje por Refuerzo



Optimización de Rutas UPP via UCB1 Multi-Armed Bandit

Modelo Predictivo OLS y Tomador de Decisiones Adaptativo para Despacho

Integrantes del Equipo:

Angeles Sanchez Ximena Nathaly

Islas Lozada Emmanuel

Asistencia de IA:

Asistencia de IA: Google Gemini & OpenAI Codex

“Aprender directamente de la interacción con el entorno es el principio fundamental del comportamiento inteligente.”

— **Richard S. Sutton**

Padre del Aprendizaje por Refuerzo Moderno y Coautor de *Reinforcement Learning: An Introduction*

Agenda General del Proyecto

color cyanAccent

Parte I: Diagnóstico y Modelado

1. **Problema Operativo UPP:**
Cuello de botella en transporte.
2. **Dataset Simulado:** Llegadas Poisson (λ diferenciado).
3. **Regresión Lineal OLS:** Modelo predictivo $Y = a + bX$.
4. **Diagnóstico Estadístico:**
Pruebas de supuestos MCO.

Parte II: Prescripción y Resultados

1. **Algoritmo UCB1:** Agente Multi-Armed Bandit.
2. **Evaluación Experimental:**
Comparativa a_0 vs UCB1.
3. **Respuestas de Negocio:**
Preguntas clave operativas.
4. **Bitácora de IA & Cierre:**
Aprendizaje analítico.

Contexto Operativo del Transporte UPP

color cyanAccent

La Dinámica del Servicio

- ▶ **Rutas Clave Evaluadas:** *Puente de Tuzos y San Agustín.*
- ▶ **Capacidad de Unidad:** Combis urbanas con capacidad de **18 pasajeros.**
- ▶ **Regla Tradicional de Operación (a_0):** Despachar el vehículo **únicamente** al alcanzar la ocupación del **100% (18 alumnos).**

Conflicto Estudiantil–Concesionario

- ▶ El concesionario busca maximizar el ingreso por viaje (18 pasajes).
- ▶ Los alumnos sufren demoras severas acumulando frustración y retardos escolares.

El Cuello de Botella en Horas Valle

color cyanAccent

Ineficiencia de la Regla Rígida a_0

- ▶ **Horas Pico (07:00–09:00, 13:00–15:00):** La combi se llena en menos de **5 minutos**. La política a_0 funciona bien.
- ▶ **Horas Valle (10:00–12:00, 16:00–18:00):** La llegada de alumnos decae drásticamente.
- ▶ **Consecuencia Severa:** Esperar a llenar los 18 asientos en hora valle provoca tiempos de espera de **60 a 84 minutos**.

Pregunta Central

¿Es posible definir una política de despacho flexible que reduzca el tiempo de espera sin mermar la rentabilidad operativa del transporte?

Dataset Simulado: Proceso Estocástico Poisson

color cyanAccent

Generación de Demanda

La llegada de estudiantes se modeló como un proceso Poisson homogéneo a trozos:

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}$$

- ▶ **Hora Pico:** $\lambda_{\text{pico}} = 3.5$ alumnos / 15 min.
- ▶ **Hora Valle:** $\lambda_{\text{valle}} = 1.2$ alumnos / 15 min.
- ▶ **Dataset:** 21 días de simulación (1,466 despachos reales).

Propiedades del Dataset

- ▶ Simulación realizada en Python con reproducibilidad estricta.
- ▶ Captura variaciones de demanda entre la mañana, tarde y noche.
- ▶ Permite evaluar políticas con escenarios sintéticos realistas.

Estructura del Dataset (13 Variables Clave)

color cyanAccent

Schema del Dataset de Transporte UPP

Variable	Descripción Operativa
fecha, hora_intervalo	Registro temporal del despacho en la terminal.
ruta	Indicador de trayecto (Puente de Tuzos / San Agustín).
alumnos_esperando	Cantidad de alumnos en cola al llegar la combi (X).
llegadas_intervalo	Alumnos adicionales que arriban durante la espera.
pasajeros_al_salir	Número final de pasajeros a bordo al salir.
tiempo_espera_acum	Tiempo total transcurrido en minutos hasta el despacho (Y).
tipo_salida	Clasificación del despacho (Llena: 18 / Parcial: < 18).

Modelo Predictivo OLS (Regresión Lineal Simple)

color cyanAccent

Formulación del Modelo MCO

Relación entre alumnos esperando al llegar la unidad (X) y tiempo restante para salir (Y):

$$Y_i = a + b \cdot X_i + e_i$$

Estimación de Coeficientes OLS:

$$b = \frac{\sum(X_i - \bar{X})(Y_i - \bar{Y})}{\sum(X_i - \bar{X})^2}, \quad a = \bar{Y} - b\bar{X}$$

Propósito del Modelo

Proporcionar una **predicción del tiempo de espera esperado** a partir de la cola inicial observada al llegar la unidad, sirviendo como insumo al sistema de decisión.

Resultados de la Regresión Lineal OLS

color cyanAccent


Ecuación Estimada del Tiempo de Espera

$$\hat{Y} = 14.1068 - 2.5395 \cdot X$$

- ▶ **Intercepto** ($a = 14.11$ min): Tiempo estimado si la combi llega sin alumnos en la cola inicial ($X = 0$).
- ▶ **Pendiente** ($b = -2.54$ min/alumno): Por cada alumno en cola al llegar, el tiempo de espera restante se reduce en 2.54 minutos.
- ▶ **Bondad de Ajuste** ($R^2 = 0.121$): El modelo explica el 12.1% de la variabilidad, con alta significancia global ($F = 201.8, p = 5.83 \times 10^{-43} < 0.001$).

Gráfica del Modelo OLS Ajustado

color cyanAccent



Diagnóstico de Supuestos Estadísticos OLS

color cyanAccent

1. Independencia (Durbin-Watson)

$DW = 1.6002$: Dentro del rango aceptable $[1.5, 2.5]$, confirmando que los errores de despachos consecutivos son independientes.

2. Linealidad

Test F cuadrático $p < 0.001$. Se observa ligera curvatura en horas valle debido al tope de 18 alumnos.

3. Homocedasticidad (Breusch-Pagan)


$LM = 25.79, p < 0.001$: Existe heterocedasticidad (varianza no constante), propia de la volatilidad entre franjas pico y valle.

4. Validez Práctica

A pesar de la heterocedasticidad, los estimadores OLS son insesgados y sirven como excelente predictor lineal baseline.

Evaluación de Heterocedasticidad en Residuos

color cyanAccent



Aprendizaje por Refuerzo: Algoritmo UCB1

color cyanAccent

Formulación del Algoritmo UCB1 (Upper Confidence Bound)

El agente selecciona la política A_t maximizando la cota superior de confianza:

$$A_t = \arg \max_a \left[\bar{Q}_t(a) + c \sqrt{\frac{\ln t}{N_t(a)}} \right]$$

- ▶ **Término de Explotación** ($\bar{Q}_t(a)$): Recompensa promedio obtenida históricamente por la regla a .
- ▶ **Término de Exploración** ($c \sqrt{\frac{\ln t}{N_t(a)}}$): Bonus de incertidumbre para brazos poco probados ($c = \sqrt{2}$).

Catálogo de Políticas de Despacho (Brazos UCB)

color cyanAccent

Políticas Operativas Evaluadas por el Agente ($a_0 \dots a_4$)

Brazo	Identificador	Regla de Despacho	Tipo de Regla
a_0	FullOnly	Salir únicamente con 18 pasajeros.	Rígida / Tradicional
a_1	Flex_14p_15m	Salir con ≥ 14 pax O tras 15 min de espera.	Dinámica Flexible
a_2	Flex_12p_25m	Salir con ≥ 12 pax O tras 25 min de espera.	Dinámica Moderada
a_3	Flex_10p_35m	Salir con ≥ 10 pax O tras 35 min de espera.	Dinámica Valle
a_4	Flex_8p_45m	Salir con ≥ 8 pax O tras 45 min de espera.	Límite Máximo

Función de Recompensa Normalizada

color cyanAccent

Penalización Multiobjetivo

$$P_t = w_1 \cdot \text{espera} + w_2 \cdot \text{dejados} + w_3 \cdot \text{vacíos}$$

Pesos del Servicio:

- ▶ $w_1 = 0.4$: Reducción del tiempo de espera.
- ▶ $w_2 = 0.4$: Evitar alumnos varados.
- ▶ $w_3 = 0.2$: Eficiencia de asientos.

Escalamiento Min-Max Invertido

Para estabilizar UCB1, la recompensa se normaliza en $R_t \in [0, 1]$:

$$R_t = 1 - \frac{P_t - P_{\min}}{P_{\max} - P_{\min}}$$


- ▶ $R_t \rightarrow 1$: Despacho óptimo.
- ▶ $R_t \rightarrow 0$: Despacho ineficiente.

Convergencia y Aprendizaje del Agente UCB1

color cyanAccent

Selección Óptima del Brazo

- ▶ El agente UCB1 aprendió a priorizar el brazo a_1 (Flex_14p_15m).
- ▶ Alcanzó la mayor recompensa promedio ($\bar{Q} = 0.692$).
- ▶ Logró salir rápido en pico y limitar la espera a máximo 15 min en valle.




Comparativa Experimental: Política a_0 vs UCB1

color cyanAccent

Desempeño Comparativo

- ▶ **Tiempo Medio:** Caída drástica de 38.4 min a 16.2 min.
- ▶ **Tiempo Máximo:** Reducción de 84.5 min a 28.1 min.
- ▶ **Ocupación Vehicular:** Mantenido por encima del 77.7%.



Matriz de Resultados Operativos

color cyanAccent

Cuadro Comparativo Global (3 Semanas de Simulación)

Métrica de Evaluación	Política Tradicional a_0	Agente UCB1 (a_1)	Mejora Alcanzada
Tiempo Promedio de Espera	38.4 min	16.2 min	-57.8% Ahorro
Tiempo Máximo de Espera	84.5 min	28.1 min	-66.7% Ahorro
Factor de Ocupación Vehicular	100.0% (18/18)	77.7% (14/18)	Equilibrio Eficiente
Alumnos Varados en Terminal	142 alumnos	12 alumnos	-91.5% Varados
Recompensa Promedio ($\bar{Q}$)	0.415	0.692	+66.7% Eficiencia

Respuestas a Preguntas Clave de Operación

color cyanAccent

1. ¿Conviene esperar cupo de 18 pax?

No en horas valle. Produce tiempos de espera inaceptables (> 60 min) colapsando el servicio estudiantil.

2. Mínimo razonable para salir

Salir con **12 a 14 pasajeros** en valle reduce la espera en más del **40%** preservando una ocupación rentable ($> 66\%$).

3. ¿En qué horas ser más flexible?

En franjas valle (10:00–12:00 y 16:00–18:00). En hora pico el vehículo se llena de forma natural en < 5 min.

4. Ahorro de tiempo con 12–14 pax

Se ahorran en promedio **22 a 30 minutos por estudiante por viaje** frente a la regla tradicional a_0 .

Evidencia de Bitácora de IA Generativa

color cyanAccent

Uso Responsable y Evaluación Crítica de IA (Codex & Gemini)

Herramienta	Tema Evaluado	Solicitud / Pregunta	Verificación y Aprendizaje
ChatGPT	Simulación Poisson	Llegadas por intervalo en Python.	Ajusté λ variable por franja (Pico=3.5, Valle=1.2) para dar realismo.
Copilot	Regresión scikit-learn	Código de ajuste OLS.	Corregí formato 2D exigido por scikit-learn y agregué etiquetas a ejes.
Gemini	Supuestos MCO	Pruebas Breusch-Pagan y DW.	Validé que la heterocedasticidad no sesga los coeficientes OLS.
Codex	Algoritmo UCB1	Recompensa multiobjetivo.	Implementé min-max scaling invertido para acotar recompensa en $[0, 1]$.

Conclusiones y Recomendaciones

color cyanAccent

Conclusiones Principales

- ▶ **Poder del Modelo OLS:** Proporcionó una tendencia estadísticamente sólida ($b = -2.54, p < 0.001$).
- ▶ **Eficacia del Agente UCB1:** Logró un ahorro del **57.8% en tiempo de espera** equilibrando ocupación y servicio.

Trabajo Futuro

- ▶ **Contextual Bandits (LinUCB):** Incorporar clima, calendario académico y tráfico vial en tiempo real.
- ▶ **Deep RL (DQN):** Gestión continua multi-terminal para la flota completa de la universidad.

“La toma de decisiones inteligente consiste en encontrar alternativas satisfactorias en un entorno complejo e incierto.”

— **Herbert A. Simon**

Premio Nobel de Economía y Pionero de la Inteligencia Artificial

¡Muchas Gracias por su Atención!

¿Preguntas o Comentarios?

Angeles Sanchez Ximena Nathaly & Islas Lozada Emmanuel