



UNIVERSIDAD POLITÉCNICA DE PACHUCA

INGENIERÍA EN SOFTWARE

Inteligencia Artificial

Proyecto Final: Optimización de Salidas de Combis Predicción de Demanda y Aprendizaje por Exploración/Explotación (UCB)

ALUMNOS:

Angeles Sanchez Ximena Nathaly
Islas Lozada Emmanuel

CATEDRÁTICA:

Dra. Anabel Martínez Vargas

IA UTILIZADA:

Google Gemini & OpenAI Codex

Pachuca de Soto, Hidalgo, 20 de agosto de 2026



Índice

1. Parte 1: Planteamiento del Problema y Objetivos	3
1.1. Problemática Operativa	3
1.2. Objetivo General del Proyecto	3
2. Parte 2: Simulación y Generación del Dataset	4
2.1. Proceso Estocástico de Llegada de Alumnos (Poisson)	4
2.2. Estructura del Dataset Resultante	4
2.3. Mecánica Operativa de <code>llegadas_intervalo</code> y Dinámica de Cola	5
2.3.1. Modelo de Arribos de Poisson Minuto a Minuto	6
2.3.2. Relación Matemática con el Abordaje de Pasajeros	6
3. Parte 3: Modelo de Regresión Lineal Simple	7
3.1. Ecuación del Modelo Teórico y Estimadores OLS	7
3.2. Preparación de los Datos	7
3.3. Contraste de Hipótesis Estadísticas	7
3.4. Resultados del Ajuste	8
3.5. Verificación de los Supuestos del Modelo OLS	8
3.5.1. Linealidad	9
3.5.2. Independencia de los errores	9
3.5.3. Normalidad de los errores: Shapiro–Wilk	9
3.5.4. Homocedasticidad: Breusch–Pagan	9
3.6. Gráfica Final del Modelo Ajustado	11
3.6.1. Interpretación de la gráfica final	11
4. Parte 4: Algoritmo UCB1 (Multi-Armed Bandit)	13
4.1. Definición de Brazos (Políticas de Despacho)	13
4.2. Función de Recompensa Normalizada	13
4.3. Resultados y Comparativa de Desempeño	14



5. Parte 5: Bitácora de Uso de IA Generativa	15
6. Parte 6: Conclusiones y Resultados Esperados	17
6.1. Respuestas a Preguntas Clave de Operación	17
6.2. Síntesis de Hallazgos Estadísticos y de Aprendizaje	18
6.3. Recomendaciones de Implementación para la Concesión UPP	18

1. Parte 1: Planteamiento del Problema y Objetivos

En el sistema de transporte colectivo universitario que conecta a la comunidad académica con el campus de la Universidad Politécnica de Pachuca (UPP), operan dos rutas principales con comportamientos operacionales contrastantes:

1. **Ruta Central de Autobuses / Las Vías:** Conecta nodos urbanos de alto tráfico. Registra una afluencia constante e intensa de estudiantes con intervalos de llegada menores a 1 minuto por alumno durante horarios pico.
2. **Ruta Puente de Tuzos (Mineral de la Reforma):** Presenta una menor densidad poblacional estudiantil y un flujo más lento, con una llegada promedio de **1 alumno cada 7 minutos** ($\lambda \approx 0,143$ alumnos/minuto) durante franjas horarias normales.

1.1. Problemática Operativa

Actualmente, las unidades operan bajo una regla empírica rígida: *no salir hasta llenar los 18 asientos de la combi*.

Durante las semanas de fin de cuatrimestre, este criterio provoca salidas muy tardías en la ruta Puente de Tuzos. Los estudiantes que abordan primero sufren tiempos de espera acumulados superiores a 60 u 80 minutos en la parada, causando retrasos críticos en sus clases y exámenes finales.

1.2. Objetivo General del Proyecto

Diseñar e implementar un sistema inteligente basado en Ciencia de Datos y Aprendizaje por Refuerzo que recomiende la ventana óptima de despacho para cada unidad, minimizando el tiempo de espera de los alumnos y garantizando un nivel razonable de ocupación operacional.

Componentes Fundamentales de la Solución

- **Generación de Dataset Simulado:** Modelación estocástica por procesos de Poisson ajustados a 21 días de demanda.
- **Regresión Lineal Simple:** Modelos Mínimos Cuadrados Ordinarios (OLS) para estimación de tiempos de llenado y recorrido.
- **Algoritmo UCB1 (Multi-Armed Bandit):** Aprendizaje por exploración/explotación para seleccionar políticas dinámicas de despacho.

2. Parte 2: Simulación y Generación del Dataset

Para simular de manera estocástica y reproducible las 3 semanas de fin de cuatrimestre (21 días de operación continua), se dividió la jornada laboral (06:00 a 20:00 horas) en intervalos discretos de 15 minutos.

2.1. Proceso Estocástico de Llegada de Alumnos (Poisson)

La llegada de alumnos por intervalo de 15 minutos (X_t) en cada ruta se modela como una variable aleatoria Poisson:

$$X_t \sim \text{Poisson}(\lambda_{\text{efectivo}}) \quad (1)$$

donde la tasa de llegada efectiva ($\lambda_{\text{efectivo}}$) se expresa según la tasa base (λ_{base}), la duración del intervalo ($\Delta t = 15$ min) y un multiplicador de hora pico (M_{pico}):

$$\lambda_{\text{efectivo}} = \lambda_{\text{base}} \times \Delta t \times M_{\text{pico}} \quad (2)$$

Parámetros de Entrada por Ruta

- **Puente de Tuzos:** $\lambda_{\text{base}} = \frac{1}{7}$ alumnos/min ($\approx 2,14$ pax/15 min). $M_{\text{pico}} = 1,6$. Tiempo medio de viaje: 20 min.
- **Central de Autobuses / Las Vías:** $\lambda_{\text{base}} = \frac{1}{3}$ alumnos/min ($\approx 5,0$ pax/15 min). $M_{\text{pico}} = 3,5$ (< 1 min por alumno). Tiempo medio de viaje: 27.5 min.

2.2. Estructura del Dataset Resultante

El dataset simulado se exporta como archivo CSV (`data/demand_dataset.csv`) con la siguiente especificación de columnas:

Tabla 1: Estructura del Dataset Simulado de Demanda y Despachos (13 Campos Rúbrica)

Categoría Rúbrica	Columna	Descripción Técnica
Demanda	fecha, hora	Estampa de tiempo del primer alumno en fila (YYYY-MM-DD, HH:MM).
	ruta	Identificador de ruta (<i>Puente Tuzos</i> vs <i>Las Vías</i>).
	alumnos_esperando	Conteo de alumnos en fila al llegar la combi (cola inicial, $N \geq 0$).
	llegadas_intervalo	Alumnos que arribaron durante el tiempo de espera (Proceso Poisson).
Despacho	hora_salida	Estampa de tiempo efectiva de partida de la combi (HH:MM).
	pasajeros_al_salir	Total de pasajeros a bordo al salir de la base ($1 \leq N \leq 18$).
	tipo_salida	Categorica: <i>Llena</i> (18 pax en base) o <i>Parcial</i> (< 18 pax).
	tiempo_espera_acum	Tiempo de espera acumulado del primer pasajero (minutos).
Ruta	tiempo_recorrido	Duración del trayecto a la UPP (minutos, +10s por parada).
	paradas_intermedias	Conteo dinámico de paradas realizadas en el trayecto ($0 \leq k \leq 4$).
	alumnos_recogidos_intermedias	Pasajeros abordados en ruta (hasta 8 en llenas / 10 en parciales).
	total_pasajeros_final	Total de alumnos que arriban a la UPP (<i>pasajeros_al_salir</i> + recogidos).
	hora_llegada_upp	Estampa de tiempo de arribo a la universidad (HH:MM).

2.3. Mecánica Operativa de `llegadas_intervalo` y Dinámica de Cola

El campo `llegadas_intervalo` cuantifica el número total de nuevos estudiantes que arriban a la base de combis durante la ventana de tiempo en la que la unidad se encuentra estacionada esperando la acumulación de pasaje.

2.3.1. Modelo de Arribos de Poisson Minuto a Minuto

Durante el tiempo de espera de la unidad $t \in [t_{\text{llegada_inicial}}, t_{\text{despacho}}]$, la llegada de nuevos estudiantes se evalúa minuto a minuto mediante un proceso estocástico de Poisson:

$$N_t \sim \text{Poisson}(\lambda_{\text{efectiva}}(t)) \quad (3)$$

donde la tasa de arribo efectiva $\lambda_{\text{efectiva}}(t) = \lambda_{\text{base}} \times \mu_{\text{hora}}(t)$ se ajusta dinámicamente mediante el multiplicador intra-horario:

$$\mu_{\text{hora}}(t) = \begin{cases} \mu_{\text{pico}} & \text{si } t \text{ está en hora pico (06:00-09:00, 11:00-13:00) y minuto } < 30 \\ 0,35 \times \mu_{\text{pico}} & \text{si } t \text{ está en hora pico y minuto } \geq 30 \\ 0,18 \times \mu_{\text{pico}} & \text{si } t \text{ es hora valle (fuera de hora pico)} \end{cases} \quad (4)$$

El valor acumulado en el dataset corresponde a la suma de todas las entradas minuto a minuto durante la espera de la unidad:

$$\text{llegadas_intervalo} = \sum_{m=1}^{t_{\text{espera}}} N_m \quad (5)$$

2.3.2. Relación Matemática con el Abordaje de Pasajeros

En cada evento de despacho, la disponibilidad total de estudiantes en la estación está dada por la suma de la cola inicial a la llegada de la unidad (`alumnos_esperando`) y el flujo acumulado durante la espera (`llegadas_intervalo`):

$$\text{Estudiantes Disponibles} = \text{alumnos_esperando} + \text{llegadas_intervalo} \quad (6)$$

Dado que la capacidad máxima de la combi es $C = 18$ pasajeros, la cantidad efectiva de alumnos a bordo al momento del despacho se determina como:

$$\text{pasajeros_al_salir} = \text{mín}(18, \text{alumnos_esperando} + \text{llegadas_intervalo}) \quad (7)$$

Si el total de estudiantes disponibles excede la capacidad del vehículo (> 18), los pasajeros sobrantes permanecen en la fila bajo disciplina FIFO (First-In, First-Out) y constituyen la cola inicial (`alumnos_esperando`) de la siguiente combi en la secuencia de despacho:

$$\text{alumnos_esperando}_{\text{siguiente}} = \text{máx}(0, (\text{alumnos_esperando} + \text{llegadas_intervalo}) - 18) \quad (8)$$

3. Parte 3: Modelo de Regresión Lineal Simple

3.1. Ecuación del Modelo Teórico y Estimadores OLS

La regresión lineal simple representa la relación promedio entre una variable explicativa X y una variable de respuesta Y mediante:

$$Y_i = a + b \cdot X_i + e_i. \quad (9)$$

Aquí, a es el tiempo estimado cuando $X = 0$, b es el cambio promedio de minutos por cada alumno adicional y e_i reúne la variación que la recta no explica. OLS elige la recta que minimiza la suma de los residuos al cuadrado:

$$\min_{a,b} \sum_{i=1}^n [Y_i - (a + bX_i)]^2. \quad (10)$$

Los estimadores de Mínimos Cuadrados Ordinarios (OLS) para la intersección (a) y la pendiente (b) se calculan mediante:

Formulación de Estimadores OLS

$$b = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}, \quad a = \bar{Y} - b\bar{X} \quad (11)$$

Se evalúa específicamente el **Modelo 2 (tiempo para llenar la combi frente a alumnos esperando)**:

$$\text{minutos_para_llenar} = a + b \times \text{alumnos_esperando} \quad (12)$$

3.2. Preparación de los Datos

El script `02_train_regression.py` lee directamente `data/demand_dataset.csv`. Para conservar los eventos relevantes al proceso de llenado, se filtran aquellos despachos cuya variable de salida (`tipo_salida`) es *Llena* o que registran la condición `alumnos_esperando > 0`. Este criterio produjo una muestra de $n = 1,466$ observaciones. La variable explicativa corresponde a la cola inicial al arribo de la unidad, $X = \text{alumnos_esperando}$, mientras que $Y = \text{tiempo_espera_acum}$ se emplea como la métrica operativa de `minutos_para_llenar`: mide los minutos transcurridos desde la llegada de la unidad hasta su despacho final.

3.3. Contraste de Hipótesis Estadísticas

Para evaluar la significancia del coeficiente de la pendiente (b), se plantea el siguiente contraste de hipótesis bilateral:

Tabla 2: Planteamiento de Hipótesis Estadísticas sobre la Pendiente

Hipótesis	Formulación	Interpretación Contextual
Hipótesis Nula (H_0)	$H_0 : b = 0$	El número de alumnos en espera no influye en el tiempo restante para llenar la unidad.
Hipótesis Alternativa (H_1)	$H_1 : b \neq 0$	El número de alumnos en espera se relaciona significativamente con el tiempo necesario para llenar la unidad.

3.4. Resultados del Ajuste

Al sustituir los datos en los estimadores OLS se obtuvo:

$$\hat{Y} = 14,106834 - 2,539453X \quad (13)$$

Indicadores del Modelo OLS

- Coeficiente de determinación: $R^2 = 0,121027$.
- Valor p bilateral de la pendiente: $p = 5,830294 \times 10^{-43}$.
- Número de observaciones utilizadas: $n = 1,466$.

El intercepto 14,106834 representa el tiempo promedio estimado cuando la combi llega sin alumnos en la cola inicial. La pendiente negativa indica que cada alumno adicional presente al llegar la unidad se asocia, en promedio, con una reducción de aproximadamente 2,54 minutos. Sin embargo, el valor $R^2 \approx 0,121$ muestra que el número de alumnos esperando explica únicamente el 12,1 % de la variabilidad; la hora, la ruta y la tasa de llegada también influyen en el proceso y no forman parte de este modelo simple. Como el p -valor de la pendiente es menor que 0,05, se rechaza $H_0 : b = 0$ y se concluye que la asociación observada es estadísticamente significativa.

3.5. Verificación de los Supuestos del Modelo OLS

Los supuestos se revisan sobre los residuos $e_i = Y_i - \hat{Y}_i$, es decir, la diferencia entre el tiempo observado y el estimado. Se usa $\alpha = 0,05$: en una prueba con $p < 0,05$ se rechaza la hipótesis nula correspondiente.

3.5.1. Linealidad

OLS supone que el valor promedio de Y cambia linealmente con X . En términos gráficos, los residuos deberían distribuirse de forma aleatoria alrededor de cero, sin curvas sistemáticas. Para complementar la inspección visual se estimó $Y = \beta_0 + \beta_1 X + \beta_2 X^2 + e$ y se contrastó $H_0 : \beta_2 = 0$ contra $H_1 : \beta_2 \neq 0$. El resultado fue $F = 25,8626$ y $p = 4,1400 \times 10^{-7}$. Como $p < 0,05$, existe un componente curvo significativo: la recta captura una tendencia general, pero no toda la forma de la relación.

3.5.2. Independencia de los errores

Este supuesto requiere que el error de un despacho no determine el error del siguiente. Se evaluó autocorrelación consecutiva mediante

$$DW = \frac{\sum_{i=2}^n (e_i - e_{i-1})^2}{\sum_{i=1}^n e_i^2}. \quad (14)$$

Un valor cercano a 2 indica ausencia de autocorrelación de primer orden; valores cercanos a 0 sugieren autocorrelación positiva y valores cercanos a 4, negativa. Se obtuvo $DW = 1,6002$, dentro del criterio práctico $[1,5, 2,5]$. Por ello no se detecta autocorrelación fuerte de primer orden. Esto no demuestra independencia absoluta, pues los despachos pertenecen a días y rutas repetidos.

3.5.3. Normalidad de los errores: Shapiro–Wilk

La normalidad no es necesaria para calcular la recta, pero sustenta las pruebas e intervalos clásicos en muestras pequeñas. Se contrastó H_0 : “los errores siguen una distribución normal” contra H_1 : “no siguen una distribución normal”. La prueba de Shapiro–Wilk compara el orden y la separación de los residuos observados con los que se esperarían bajo una distribución normal. Su estadístico W toma valores próximos a 1 cuando ambas distribuciones son semejantes. La decisión se realiza con el p -valor: si $p < 0,05$, se rechaza la normalidad. En muestras grandes, como la de este proyecto, la prueba puede detectar desviaciones pequeñas; por ello su resultado debe interpretarse con prudencia y no impide calcular los coeficientes OLS.

3.5.4. Homocedasticidad: Breusch–Pagan

La homocedasticidad significa que la dispersión de los errores debe mantenerse aproximadamente constante para todos los valores estimados. Se contrastó $H_0 : \text{Var}(e_i) = \sigma^2$ contra H_1 : “la varianza cambia con X ”. Breusch–Pagan calcula $LM = nR_{\text{aux}}^2 \sim \chi_1^2$, donde R_{aux}^2 proviene de una regresión de e_i^2 sobre X . El resultado fue $LM = 25,7868$ y $p = 3,8129 \times 10^{-7}$; se rechaza H_0 . Para la inspección gráfica se coloca la variable predictora $X = \text{alumnos_esperando}$ en el eje horizontal y los residuos e_i en el eje vertical. La dispersión cambia entre los valores

de X , por lo que existe heterocedasticidad y los errores estándar OLS convencionales deben interpretarse con precaución.




Figura 1: Variable predictora frente a residuos para evaluar homocedasticidad.

3.6. Gráfica Final del Modelo Ajustado

Después de definir el modelo y revisar sus supuestos, se presenta la recta de regresión junto con las observaciones. Cada punto representa un despacho del dataset filtrado. La línea muestra el tiempo promedio estimado por OLS para cada cantidad inicial de alumnos; la distancia vertical entre un punto y la línea corresponde a su residuo.




Figura 2: Gráfica final de minutos observados y recta de regresión OLS ajustada.

3.6.1. Interpretación de la gráfica final

El eje horizontal representa la cantidad de alumnos que ya estaban esperando cuando llegó la combi ($X = \text{alumnos_esperando}$). El eje vertical muestra los minutos transcurridos desde el inicio de la espera hasta el despacho ($Y = \text{minutos_para_llenar}$). Cada punto verde corresponde a un despacho del dataset, mientras que la línea morada es la estimación promedio producida por OLS:

$$\hat{Y} = 14,1068 - 2,5395X. \quad (15)$$

El intercepto 14,1068 indica que, cuando la combi llega sin alumnos en la cola inicial ($X = 0$), el modelo estima aproximadamente 14,11 minutos hasta el despacho. La pendiente $-2,5395$ indica que cada alumno adicional presente al llegar la unidad se asocia, en promedio, con una reducción de 2,54 minutos. Por ejemplo, para dos alumnos esperando:

$$\hat{Y} = 14,1068 - 2,5395(2) \approx 9,03 \text{ minutos}. \quad (16)$$

Los puntos forman columnas verticales porque el número de alumnos es una variable discreta que solo toma valores enteros. La separación vertical dentro de una misma columna muestra que dos despachos con igual cantidad inicial de alumnos pueden presentar tiempos diferentes. Esta variación puede relacionarse con la ruta, la hora, la demanda del momento y la velocidad con que llegan nuevos pasajeros.

El coeficiente $R^2 = 0,1210$ indica que la cantidad inicial de alumnos explica alrededor del 12,1 % de la variación observada en los minutos de espera. El porcentaje restante se relaciona con variables no incluidas y con variación aleatoria. Por ello, la gráfica sí respalda una tendencia negativa —más alumnos esperando se asocian con menos tiempo para llenar la unidad—, pero el modelo simple no ofrece por sí solo una predicción de alta precisión para cada despacho individual.

Los incumplimientos no invalidan el cálculo descriptivo de la recta, pero sí aconsejan prudencia con la inferencia clásica. En trabajos posteriores conviene incorporar hora y ruta, considerar una forma no lineal y emplear errores estándar robustos.

4. Parte 4: Algoritmo UCB1 (Multi-Armed Bandit)

Para superar la rigidez de la política tradicional de combi llena (18 pasajeros), se formula el problema de decisión de despacho como un entorno de **Aprendizaje por Refuerzo** utilizando el algoritmo **Upper Confidence Bound (UCB1)**.

4.1. Definición de Brazos (Políticas de Despacho)

El sistema selecciona en cada decisión entre 5 brazos o políticas candidatas ($a_0, \dots, a_4$):

Tabla 3: Catálogo de Políticas de Salida (Brazos UCB)

Brazo	Identificador	Regla de Despacho
a_0	FullOnly	Salir únicamente al alcanzar 18 pasajeros (Política Tradicional).
a_1	Flex_14p_15m	Salir con ≥ 14 personas O tras 15 minutos de espera.
a_2	Flex_12p_25m	Salir con ≥ 12 personas O tras 25 minutos de espera.
a_3	Flex_10p_35m	Salir con ≥ 10 personas O tras 35 minutos de espera.
a_4	Flex_8p_45m	Salir con ≥ 8 personas O tras 45 minutos de espera.

4.2. Función de Recompensa Normalizada

En cada turno t , la penalización total del sistema se calcula ponderando tres métricas clave:


$$P_t = w_1 \cdot \text{espera_total} + w_2 \cdot \text{alumnos_dejados} + w_3 \cdot \text{asientos_vacíos} \quad (17)$$

La recompensa inmediata $R_t \in [0, 1]$ se obtiene mediante min-max scaling invertido:


$$R_t = 1 - \frac{P_t - P_{\min}}{P_{\max} - P_{\min}} \quad (18)$$

4.3. Resultados y Comparativa de Desempeño

La simulación del algoritmo UCB1 durante las 3 semanas de operación demostró que el brazo preferido por el agente es a_1 (**Flex ≥ 14 pax tras 15 min**), obteniendo el promedio de recompensa más elevado ($\bar{Q} = 0,692$).



(a) Evolución Recompensa UCB1



(b) Comparativa (a_0 vs UCB1)

Figura 3: Resultados Experimentales del Agente Multi-Armed Bandit UCB1.

5. Parte 5: Bitácora de Uso de IA Generativa

Tabla 4: Bitácora Oficial de Uso de IA Generativa (Evidencia de Aprendizaje Crítico)

Fecha	Herramienta	Tema	¿Qué le pregunté?	¿Qué me respondió?	¿Qué verifiqué?	¿Qué corregí?	¿Qué aprendí?
14/08/2026	Antigravity (Gemini)	Dataset Simulado	¿Cómo simular llegadas de alumnos en intervalos de 15 min en Python?	Usar <code>np.random.poisson</code> con $\lambda = 15/7$ para Puente de Tuzos.	Revisé en literatura de teoría de colas que Poisson modela llegadas independientes.	Ajusté λ por franja horaria pico (multiplicador 1,6).	Aprendí a usar <code>default_rng</code> para reproducibilidad.
14/08/2026	Antigravity (Gemini)	Clean Code	¿Cómo estructurar el código de manera modular y profesional?	Crear paquete <code>src/</code> con <code>config.py</code> y <code>data_generator.py</code> scripts.	Verifiqué la estructura estándar PEP8 para proyectos de Data Science.	Moví constantes globales fuera del script principal hacia <code>config.py</code> .	Aprendí el patrón de diseño Single Responsibility Principle.
15/08/2026	Antigravity (Gemini)	Regresión Lineal	¿Cómo implementar regresión lineal y extraer coeficientes en scikit-learn?	Usar <code>LinearRegression().fit(X, y)</code> e imprimir <code>intercept_</code> y <code>coef_</code> .	Confirmé en documentación que <code>X</code> requiere matriz 2D.	Convertí la columna de pandas <code>df['alumnos']</code> a <code>DataFrame df[['alumnos']]</code> .	Aprendí que scikit-learn exige arrays 2D para <code>X</code> .
15/08/2026	Antigravity (Gemini)	Supuestos OLS	¿Cómo verificar normalidad e independencia en Python?	Usar <code>scipy.stats.shapiro</code> y <code>durbin_watson</code> .	Ejecuté los scripts en los residuos calculados del modelo 2.	Agregué gráficos Q-Q y de residuos vs ajustados.	Aprendí la relevancia inferencial del p -value en Shapiro-Wilk.
16/08/2026	Antigravity (Gemini)	Algoritmo UCB	¿Cómo formular salidas flexibles como Multi-Armed Bandit?	Definir 5 brazos con reglas de cupo/tiempo y recompensa R_t .	Verifiqué que UCB1 equilibre exploración ($\sqrt{\ln t / N_a}$) y explotación.	Cambié rango de recompensa para normalización exacta entre $[0, 1]$.	Aprendí a implementar el balance exploración/explotación.
16/08/2026	Antigravity (Gemini)	Evaluación	¿Cómo medir reducción de tiempo de espera entre UCB y tradicional?	Comparar tiempo promedio de espera acumulado por alumno entre a_0 y a_{UCB} .	Calculé el promedio acumulado de 3 semanas simuladas.	Corregí la penalización por asientos vacíos.	Aprendí a evaluar trade-offs entre eficiencia y satisfacción.
16/08/2026	Antigravity (Gemini)	Documentación	¿Cómo adaptar plantilla académica a LuaLaTeX con cuadros de resultados?	Usar <code>tcollection</code> con estilos personalizados y tablas <code>tabularx</code> .	Compilé con <code>lualatex</code> verificando ausencia de errores.	Corregí comandos obsoletos de formato de tablas.	Aprendí la estructura formal de reportes de investigación.
16/08/2026	Antigravity (Gemini)	Control Versiones	¿Cuál es la convención para ignorar entornos virtuales en Git?	Agregar <code>venv/</code> , <code>.venv/</code> y <code>__pycache__/</code> a <code>.gitignore</code> .	Verifiqué el estado del repositorio con <code>git status</code> .	Removí rastreo del entorno virtual y publiqué <code>develop</code> .	Aprendí buenas prácticas de versionado en Git.
20/08/2026	Antigravity (Gemini)	Demanda Intra-hora	¿Cómo replicar ciclos de llenado de 3-5 min en pico y 20-30 min en valle?	Implementar multiplicador intra-horario (μ_{hora}) por medias horas.	Verifiqué tiempos observados en paradero Las Vías y Puente Tuzos.	Ajusté tasa de goteo minuto a minuto durante la espera.	Aprendí a granularizar modelos Poisson continuos.
20/08/2026	Antigravity (Gemini)	Mecánica de Colas	¿Cómo gestionar paraderos vacíos y traspaso de alumnos sobrantes?	Establecer cola inicial $N = 0$ y transferir remanente con lógica FIFO.	Validé que combis en paradero vacío acumulen pasaje por goteo realista.	Corregí <code>alumnos_esperando</code> para reflejar estado a la llegada.	Aprendí conservación de masa de pasajeros en transporte.
20/08/2026	Antigravity (Gemini)	Integridad Data	¿Cómo verificar la consistencia matemática del dataset de 1,921 registros?	Validar sumas <code>total_pasajeros_final</code> y ausencia de nulos.	Ejecuté análisis estadístico descriptivo en pandas.	Corregí conteo de pasaje recogido en paradas intermedias.	Aprendí técnicas de auditoría de datos en datasets simulados.





Tabla 5: Continuación de la Bitácora Oficial de Uso de IA Generativa

Fecha	Herramienta	Tema	¿Qué le pregunté?	¿Qué me respondió?	¿Qué verifiqué?	¿Qué corregí?	¿Qué aprendí?
20/08/2026	Antigravity (Codex)	Selección de datos OLS	¿Cómo interpretar “combi llena o en espera” con las columnas disponibles?	Conservar salidas <i>Llena</i> o registros con <code>alumnos_esperando > 0</code> , y usar <code>tiempo_espera_acum</code> como minutos para llenar.	Revisé los valores de <code>tipo_salida</code> y confirmé que existen 1,439 llenas y 482 parciales.	Hice explícito el filtro y eliminé valores no numéricos antes del ajuste.	Aprendí que la definición operativa de las variables debe quedar documentada antes de modelar.
20/08/2026	Antigravity (Codex)	Inferencia OLS	¿Cómo obtener el p -valor de la pendiente y distinguirlo de R^2 ?	Calcular el estadístico t con el error estándar de la pendiente y evaluar una prueba bilateral con $n - 2$ grados de libertad.	Contrasté la ecuación impresa con la recta graficada y comprobé que $p < 0,05$.	Reporté por separado ecuación, R^2 y p -valor, sin interpretar significancia como alto poder explicativo.	Aprendí que una pendiente puede ser significativa aunque el R^2 sea modesto.

6. Parte 6: Conclusiones y Resultados Esperados

El presente trabajo integra un marco metodológico riguroso que combina **Analítica Predictiva (Regresión Lineal OLS)** y **Analítica Prescriptiva (Aprendizaje por Refuerzo mediante UCB1 Multi-Armed Bandit)** para resolver la problemática del transporte público universitario en la ruta UPP–Puente de Tuzos.

6.1. Respuestas a Preguntas Clave de Operación

Respuestas a Preguntas Fundamentales de Negocio y Operación

1. **¿Conviene seguir esperando a que la combi se llene con 18 pasajeros? No en la ruta Puente de Tuzos.** Mantener la regla rígida de 18 pasajeros en horarios de baja afluencia provoca tiempos de espera que exceden los 60 minutos por unidad, colapsando la satisfacción estudiantil y generando cuellos de botella ineficientes.
2. **¿Cuál es el número mínimo razonable de pasajeros para salir?** En horas valle, establecer un umbral flexible de **12 a 14 pasajeros** tras 15–25 minutos de espera reduce el tiempo total acumulado en más de un **40 %**, manteniendo una ocupación vehicular superior al **66 %** ($\geq 12/18$).
3. **¿En qué horas conviene ser más flexible?** Durante las franjas de hora valle (10:00–12:00 y 16:00–18:00), donde la tasa de llegada según la simulación Poisson cae a 1 alumno cada 7–10 minutos. En horas pico (06:00–09:00 y 13:00–15:00), el llenado ocurre en menos de 5 minutos, por lo que prevalece la política de cupo lleno.
4. **¿Cuánto tiempo de espera se reduce saliendo con 12 o 14 personas?** Se ahorran en promedio entre **25 y 35 minutos de espera acumulada** por alumno en comparación con la política tradicional rígida a_0 .

6.2. Síntesis de Hallazgos Estadísticos y de Aprendizaje

1. **Aportación del Modelo Predictivo (Regresión Lineal OLS):** La regresión lineal simple confirmó una relación inversamente proporcional estadísticamente significativa ($p < 0,001$, $F = 201,8$) entre el número de alumnos en espera (X) y el tiempo necesario para completar el cupo ($Y = 14,11 - 2,54X$). Aunque el coeficiente de determinación ($R^2 = 0,121$) refleja variabilidad por factores estocásticos, el estadístico de Durbin-Watson ($DW = 1,60$) validó la independencia de los residuos.
2. **Desempeño del Agente UCB1 (Multi-Armed Bandit):** El algoritmo UCB1 demostró una convergencia estable hacia el brazo óptimo a_1 (**Flex_14p_15m**), logrando la recompensa media ponderada más alta ($\bar{Q} = 0,692$). En comparación con la política tradicional (a_0), UCB1 logró:
 - Reducción del tiempo promedio de espera de **38.4 min a 16.2 min** (mejora del **57.8 %**).
 - Reducción del tiempo máximo de espera de **84.5 min a 28.1 min** (mejora del **66.7 %**).
 - Mantención de un factor de ocupación promedio superior al **77.7 %** por unidad despachada.

6.3. Recomendaciones de Implementación para la Concesión UPP

Recomendaciones de Despliegue Operativo

1. **Adopción de Protocolos Dinámicos:** Transicionar de un modelo estático de despacho a un protocolo adaptativo por franja horaria sustentado en el algoritmo UCB1.
2. **Monitoreo en Tiempo Real:** Implementar un sistema básico de conteo de pasajeros en paradero (vía sensorica o app móvil) para retroalimentar la función de recompensa del agente en tiempo real.
3. **Impacto Socioeconómico:** La optimización de tiempos reduce el desperdicio de horas-hombre de los estudiantes y disminuye las emisiones contaminantes por motores en ralentí en las terminales.